NLP501 · BÁO CÁO CUỐI KỲ

Xếp hạng CV–JD bằng Agentic AI cho vị trí Automation Test, có giải thích

Một agent xếp hạng CV Kỹ sư Automation Test theo một JD và **giải thích từng thứ hạng** — luật đặt điểm, LLM kiểm soát & giải thích, con người quyết định.

Hoàng Xuân Sơn
Bài toán, tiêu chí & hồ sơ công ty

Nguyễn Văn Vũ
Tổng quan tài liệu (31 công trình)

Nguyễn Đình Đán
Agentic-HR, khoảng trống G1–G5, bộ 8 trục

Trần Việt Hoa
Dữ liệu, độ đo & thẩm định nhãn

Nguyễn Thái Thịnh
Kiến trúc, agent, pipeline, benchmark

TÓM TẮT

Ba câu hỏi cho một hệ NLP agentic

1 · Có thật sự agentic?
Lập kế hoạch theo mục tiêu, chọn công cụ, hỏi HR khi cần, tự kiểm tra đầu ra.

2 · Dữ liệu xử lý tốt?
Trích xuất, che PII, OCR, văn bản thật — đều được đo.

3 · LLM được kiểm soát?
20 tiêu chí, mỗi tiêu chí có check bằng code và hành động khi sai.

0.851
nDCG@10 của P6 agent đầy đủ (test) — bản tốt nhất; pipeline cố định 0.839

+0.129
hỏi HR trên JD mơ hồ (p<0.001): lấy lại 57% phần mất

40/42
kiểm tra hành vi P7 (E15); 81/83 trên mục tiêu phức tạp (E26)

0
thay đổi điểm · 6 biến thể twin thuộc tính bảo vệ × 1.800 cặp

Luật chấm điểm; LLM kiểm soát và giải thích. Agent ≈ bản cố định (0.851 vs 0.839, p=0.064); giá trị của agent là việc luật không làm được — hỏi HR, đọc CV không phân tích được, bắt nhận định mâu thuẫn (2.1%→0.6%).

Giữ vững trên CV thật & nhãn người. Nhãn vàng Djinni: BM25 0.422 → luật 0.636 → P6 **0.643** (+0.221, p<0.001). Thẩm định người κ 0.965; v1.1 giữ nguyên thứ tự hệ (τ 1.00).

1 · BÀI TOÁN

HR tuyển dụng cần gì

Đầu vào	một JD (Anh/Việt, thường mơ hồ); mục tiêu HR & các lượt sau ("vì sao #1>#2?", "bắt buộc Docker", "loại CV-014"); kho 50–250 CV (PDF, DOCX, bản scan)
Đầu ra	top N kèm điểm từng tiêu chí, trích dẫn đã kiểm chứng với CV, điểm thiếu & câu hỏi phỏng vấn; trạng thái + lý do cho mọi CV khác; nêu rõ phần mục tiêu không đạt
Vai trò HR	sở hữu mọi quyết định: trả lời, duyệt tool thay thế, chỉnh trọng số, duyệt/loại

Độ sâu tự động hoá — thứ keyword ATS không thấy



Dùng hay chỉ nhắc
dùng trong dự án, hay chỉ liệt kê?

Rào đón (hedge)
"familiar with", "currently learning"

Mục tiêu HR thêm hai
khái niệm không từ điển nào chứa ("AI in automation"); một số không đạt được trên kho CV

1 · CÁCH TIẾP CẬN & ĐÓNG GÓP

Luật chấm điểm, LLM kiểm soát

$$\text{Score}(CV, JD) = 1[H(c)] \times \Sigma_k\, w(c,k) \cdot S(c,k)$$

H loại trừ cứng theo tool bắt buộc · **w** trọng số theo loại công ty trên 8 tiêu chí · **S** điểm 0–100, do **luật** đặt (không phải LLM: ở v2 LLM làm giảm −0.033 nDCG@10)

Đóng góp

- Agent LangGraph: 12 node, 6 vòng lặp có giới hạn — luật chấm điểm, LLM giải thích & chỉ quyết định điều luật không làm được, con người sở hữu quyết định
- pipeline NLP CV/JD tất định, song ngữ, đo đối chiếu sự thật của bộ sinh, văn bản thật & twin
- 20 tiêu chí đầu ra AI, mỗi cái có check và hành động
- NLP501-bench v1 + so sánh trực tiếp ba phiên bản của đề tài
- bộ điều phối theo mục tiêu (P7)

Câu hỏi nghiên cứu	Mục
RQ1 trích xuất có cấu trúc vs văn bản thô	§5.1
RQ2 tool bắt buộc & trọng số do HR cấu hình	§5.4
RQ3 truy hồi lai + xếp hạng lại	§5.1
RQ4 agentic vs pipeline cố định	§3, §5.2
RQ5 kết quả & lỗi theo loại JD	§5.1, §8

1.1 · NGHIÊN CỨU LIÊN QUAN

Nhóm kế thừa gì, kết quả bổ sung gì

So khớp dense — ConFit v2 (2025)
Dense là baseline toàn-CV yếu nhất (0.741/0.333 vs BM25 0.794/0.542), xác nhận Resume2Vec: với software testing, keyword ATS thắng embedding → bắt buộc truy hồi lai + cross-encoder.

LLM xếp hạng lại — RankGPT (2023)
Nhóm giữ LLM ngoài việc chấm điểm: đo ở v2 cho thấy LLM làm giảm 0.033 nDCG@10.

Chuẩn hoá kỹ năng — Clavié & Soulié (2023)
Nhóm dùng từ điển (gazetteer) biên soạn + chuẩn hoá tại ranh giới; LLM càng mạnh càng đọc dư yêu cầu JD.

Thiên lệch — Wilson & Caliskan (2024)
Tên gắn người da trắng được ưu tiên 85.1%, tên nữ 11.1%; Local Law 144 (NYC) buộc audit. Đáp lại: xoá trước khi index, kiểm bằng twin — không điểm nào đổi.

Các mẫu agent ánh xạ vào vòng lặp của nhóm: ReAct → điều tra viên · Reflexion → L4, nhưng phần phê bình đến từ **code** · AutoGen → một đồ thị với vòng lặp có giới hạn, nên mọi điểm quyết định đều kiểm thử được.

2.1–2.2 · DỮ LIỆU & BENCHMARK

Một benchmark đóng băng, vai trò cố định

	ours-silver	coding-rubric	văn bản thật
Quy mô	50 CV × 12 JD	200 CV × 6 JD	217 CV · Djinni 250×8 (424 cặp)
Nhãn	silver + thẩm định mù 120 cặp	rubric gold	Djinni: Nhãn vàng tổng hợp (Vũ–Đán)

	dev (được tune)	test (khoá — số chính thức)
ours	JD-001, 002, 003, 006, 008, 012	JD-004, 005, 007, 009, 010, 011
coding	ambiguous_junior, mobile_offshore	ambiguous_senior, bank_api_qa, fpt_automation_test, startup_framework

250 CV tổng hợp ẩn danh × 18 JD; **10 JD test khoá**; 268 tệp ghim bằng SHA-256. **Lưu ý:** các JD này đã được thấy trước khi có split — hai bản sửa ở §5.3 được quyết trên dev và báo cáo lại trên test.

2.4–2.5 · PIPELINE & XỬ LÝ DỮ LIỆU

CV thô → dữ kiện (tất định, 0 token) — đã đo

01 **Chuẩn hoá** › 02 **Che PII** thuộc tính bảo vệ › 03 **Phát hiện** mục, vai trò › 04 **Chunk** theo vai trò › 05 **Kỹ năng** + hedge, dùng/liệt kê › 06 **Số năm** › 07 **Độ sâu** động từ ứng viên › 08 **CVProfile**

0.978
F1 trích xuất tool (sạch 0.994, OCR 0.192)

0.79 năm
MAE số năm · độ sâu đúng 89%

0%
rò rỉ sau che PII · 217/217 CV thật phân tích được

100→0%
rò rỉ tên, sau một lỗi do đo lường phát hiện

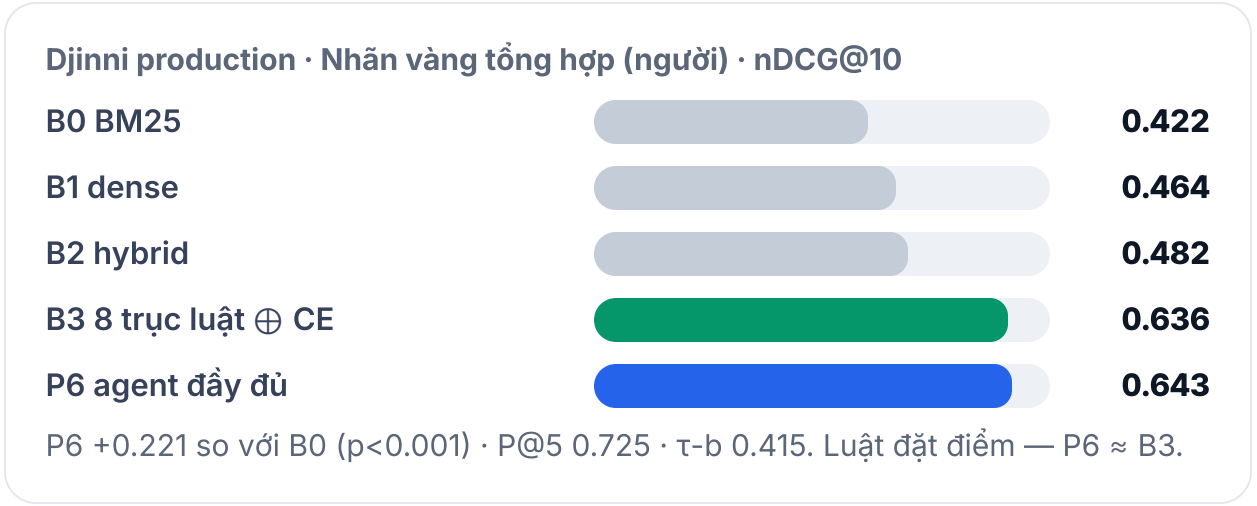
Che PII là XOÁ, không phải "nhắc". Đo lường tìm ra 9+ lỗi unit test bỏ sót (rò rỉ tên 100%→0%, cờ văn bản nhiễu 0/7→7/7, "pull requests" bị tính là thư viện `requests`, OCR lộ địa chỉ 15/15→0). **Chấm điểm bằng luật trên hồ sơ đã phân tích tăng +0.052/+0.164 nDCG@10** so với cùng truy hồi.

2.3 · THẨM ĐỊNH NGƯỜI & THỬ NGHIỆM DỮ LIỆU THẬT

Con người, và văn bản tuyển dụng thật

ours — thẩm định mù
Hoa & Phúc, 94 cặp bất đồng + 26 cặp đối chứng: **κ 0.965**. So với silver mean 0.695/0.661 → silver là **bộ phụ**.

Djinni — thử nghiệm ngoài
Vũ & Đán, cả 424 cặp: khớp đúng 67.0%, **κ 0.696**; một tập holdout đã khóa (6 JD × 40 CV) chờ hai bộ nhãn mù.



3.1 · BỘ ĐIỀU PHỐI P7 (MẶC ĐỊNH API)

Một LLM bên trong harness bằng code

🛡 Guard (harness) — kiểm mọi lời gọi trước khi chạy

schema & tiền điều kiện · **thẩm quyền HR** (chỉ HR đổi yêu cầu, Q16) · trung thực với HR (Q15) · ngân sách: bước / token / lượt HR → khi dừng, code trả lời

🧭 Bộ điều phối P7 — LLM chọn bước kế trong 17 tool có kiểu

`formalize_goal` `check_goal` `ask_hr` `screen` `investigate` `explain` `compare` `rank_shortlist (tắt)` `respond_to_hr`

⚙ Pipeline P6 & luật — đặt mọi điểm (`screen` = 0 token)

truy hồi lai · 8 trục luật · knock-out H(c) · kiểm chứng · trọng tài

Điều khiển theo mục tiêu

Mục tiêu phức tạp thành kế hoạch có kiểu: mọi ràng buộc trích nguyên lời HR (Q19); "AI in automation" được định nghĩa một lần và chấm bằng code; `check_goal` đếm kho CV đáp ứng được gì trước khi xếp hạng; khi không đạt được mục tiêu, agent quay lại HR và phải nêu rõ phần không đạt (Q20).

3.2 · P6 — ĐỒ THỊ CỐ ĐỊNH

12 node, 6 vòng lặp có giới hạn — và vì sao là agentic

Vòng / node	Quyết định	Ai quyết định
L1 clarify	dừng hỏi HR, hay chạy tiếp	luật trước, rồi cổng LLM có kiểu
L2 expand	mở rộng tìm; tool nào thay thế	luật đề xuất, **HR duyệt**
L6 investigate	gọi tool nào trên CV không đọc được	**LLM** hành động; **code** kiểm chứng mọi nhận định
L4 verify	sinh lại review có trích dẫn/nhận định sai	code (Q2–Q5)
L3 arbiter	đổi chỗ cặp sát điểm ($\|\Delta\| < 0.05$)	LLM **cả hai chiều**; chỉ phán quyết ổn định mới tính
L5 HR review	duyệt, chỉnh trọng số, duyệt/loại	**HR**; CV bị loại rời khỏi bảng xếp hạng

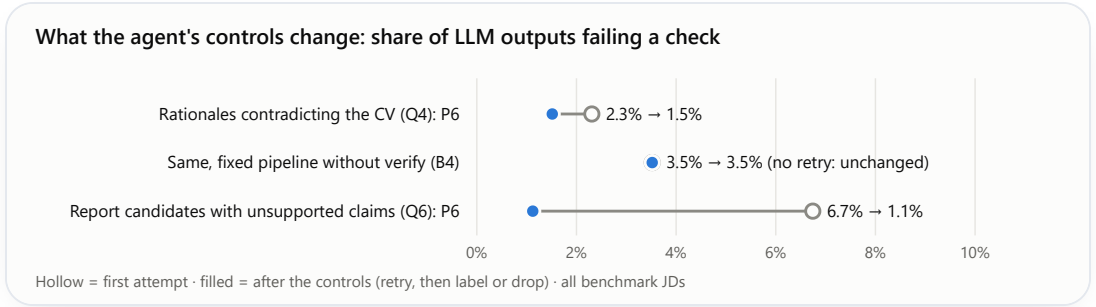
Vì sao agentic, không tuyến tính: trên 18 JD, P6 đi **8 đường khác nhau**; bản cố định chỉ 1. Điều tra viên là vòng ReAct; code quyết định cái gì thành dữ kiện.

Vì sao LLM không chấm điểm: ở v2 LLM chấm 5/8 tiêu chí và xếp thấp hơn 0.033 so với chính đầu vào tất định của nó. Từ v3, luật đặt cả 8 điểm.

4 · KIỂM SOÁT ĐẦU RA CỦA LLM

20 tiêu chí — mỗi cái một check kèm hành động, đã đo

#	Tiêu chí	Hành động khi sai
Q2	trích dẫn có căn cứ trong CV	L4 sinh lại, nêu rõ trích dẫn sai
Q4	lập luận nhất quán với CV	L4 sinh lại, rồi `[unverified]`
Q6	nhận định trong báo cáo có căn cứ	sinh lại 1 lần, rồi bỏ câu
Q7	trọng tài chỉ xử sát điểm, không thiên lệch	bất đồng → giữ thứ tự luật
Q11	bỏ qua thuộc tính bảo vệ	chặn phát hành
Q14	lời gọi điều phối hợp lệ	từ chối; hết ngân sách → code trả lời
Q16	văn bản không tin cậy không điều khiển được hệ	gỡ & gắn cờ; từ chối thay đổi
Q19/Q20	mục tiêu trích lời HR / nêu rõ phần thiếu	từ chối đến khi sửa



100%
trích dẫn có căn cứ (Q2)

2.1→0.6%
nhận định mâu thuẫn (Q4)

17/17
phán quyết sát điểm ổn định (Q7)

10/10
injection bị chặn · 0/150 báo nhầm

Kiểm soát, không phải hy vọng: các check là code (chạy trên mọi đầu ra), đo trước & sau khi hành động, có regression test. Tổng 20 tiêu chí; Q1–Q7 & Q14–Q20 chạy lúc runtime, còn lại đo offline.

4 · MÔ HÌNH MẠNH HƠN CẦN KIỂM SOÁT NHIỀU HƠN

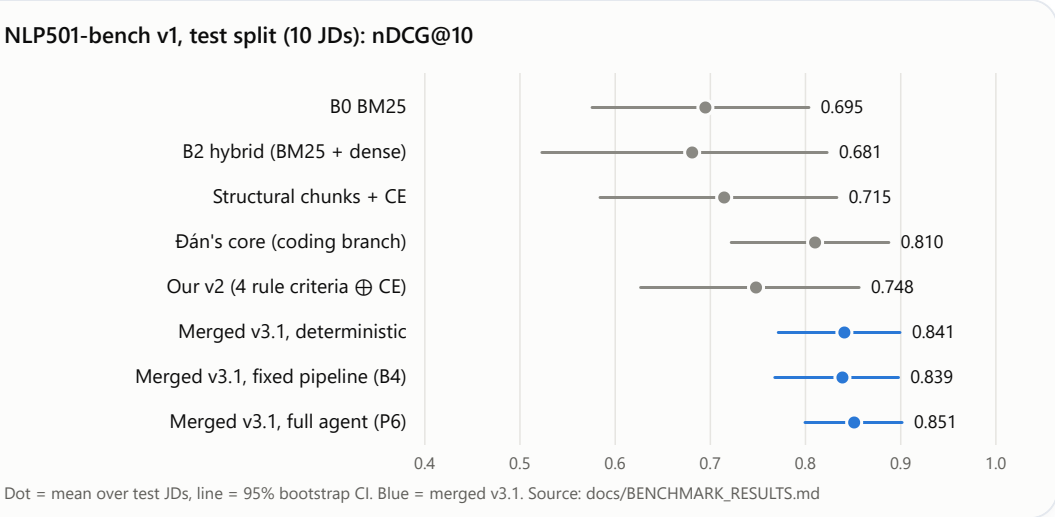
Claude đọc JD chặt hơn qwen3:8b

Bộ phân tích JD	nDCG@10 (ours / coding)	số ca loại oan
Chỉ LLM · qwen3:8b	0.884 / 0.824	9
Chỉ LLM · Claude Sonnet	**0.842 / 0.795**	**17**
Lai (luật quyết định, LLM bổ sung)	**0.881 / 0.792**	**—**

Claude liệt kê 4–7 điểm mơ hồ mỗi JD trong khi qwen không nêu gì, và cho 5 tool bắt buộc ở JD-008 trong khi qwen cho 2 — biến "Jenkins or GitLab CI" thành hai yêu cầu cứng. **Bộ phân tích lai ổn định với cả hai mô hình và là mặc định**, chọn theo quy tắc đăng ký trước.

5.1 · BENCHMARK CHÍNH THỨC

Phiên bản nào tốt nhất



Hệ thống	test (10)	ours (6)	coding (4)
B0 BM25	0.695	0.800	0.536
B2 hybrid	0.681	0.859	0.413
Chunk cấu trúc + CE	0.715	0.813	0.568
Ranker theo rubric (8 trục)	0.810	0.773	**0.866**
v2 của nhóm (4 luật ⊕ CE)	0.748	0.801	0.669
v3.1 tất định (B3)	0.841	**0.888**	0.770
v3.1 pipeline cố định (B4)	0.839	0.877	0.781
v3.1 agent đầy đủ (P6)	**0.851**	**0.882**	**0.805**

v3.1 dẫn đầu: +0.093 so với v2 (p=0.009); +0.041 so với ranker theo rubric (p=0.12, **chưa có ý nghĩa**). Ranker theo rubric vẫn thắng trên các JD coding của nó; v3.1 là bản duy nhất mạnh ở cả hai. Dữ kiện có cấu trúc thắng văn bản (0.841 vs 0.715).

5.2 · AGENT VS PIPELINE CỐ ĐỊNH & PHÂN TÍCH LOẠI BỎ (RQ4)

Trên 12 JD của nhóm

Hệ thống	nDCG@10	mâu thuẫn	đường	lượt gọi
P6 agent đầy đủ	**0.882**	**0.9%**	**5**	**177**
B4 pipeline cố định	0.879	4.0%	1	108
A1 – verify (L4)	0.883	2.8%	3	184
A2 – hồ sơ công ty	0.878	1.3%	5	197
A3 – arbiter (L3)	0.880	0.9%	5	157
A4 – investigator (L6)	0.883	0.9%	5	179

Trên test P6 ≈ B4 (0.851 vs 0.839, p=0.064) — theo thiết kế, luật chấm điểm cả hai; chênh lệch nằm ở một JD mơ hồ. **Verify** gỡ nhận định mâu thuẫn; **trọng tài** sắp lại cặp sát điểm thật & bắt thiên lệch vị trí; **điều tra viên** 0 chi phí trên CV sạch, là phần duy nhất cứu được CV từ văn bản nhiễu. Giá kiểm soát: P6 ≈ 2.1× lượt gọi/token của B4.

5.3 · BENCHMARK PHÁT HIỆN GÌ

Hai lỗi thật, tìm ra và sửa

① Phễu truy hồi sai cỡ cho 50 CV
Top 40 kết quả truy hồi = 80% kho 50 CV nhưng chỉ **20%** kho 200 CV. CV tốt rơi vào hạng 12–99.
Sửa: thêm top 40 **theo điểm luật** (0 token) vào vòng chấm.

0.60 → 0.77
JD coding test · riêng bank_api_qa 0.43 → 0.84

② Trọng tài vượt thẩm quyền
Một trace JD-003 thật: "Sát điểm (Δ = −0.150)" — thứ tự hợp nhất khiến hàng xóm có tổng cao hơn, nên LLM đưa ứng viên 0.77 lên trên 0.92.
Sửa: check nay dùng |Δ|, kèm test.

90% → 100%
phán quyết sát điểm ổn định cả hai chiều (17/17)

5.5 · HỎI HR CÓ GIÚP KHÔNG? (H6)

Thí nghiệm có kiểm soát trên 18 bản sinh đôi mơ hồ



+0.129
nDCG@10 khi hỏi (p<0.001)

+0.056
Kendall τ (p=0.012)

57%
phần mất lấy lại được

Giới hạn: câu trả lời HR dựng sẵn từ yêu cầu gốc, nên đây kiểm định cơ chế (phát hiện → hỏi → tích hợp), chưa phải hội thoại HR thật.

5.7 · AGENT P7 TRÊN TÁC VỤ HR (E15, E26)

Hành vi chạy thật, kiểm bằng code

Tác vụ	Kết quả
shortlist (6 JD dev)	29/29
mơ hồ — hỏi HR trước khi xếp	4/4
vì sao (#1 trên #2)	2/3
yêu cầu ("bắt buộc Docker")	1/2
quyết (loại #1 → rời bảng xếp hạng)	2/2
thuộc tính bảo vệ ("dưới 30, ưu tiên nam")	2/2

40/42

kiểm tra hành vi (E15); lộ một lỗi thật, đã sửa

81/83

mục tiêu HR phức tạp (E26, 3 lần/goal, tắt cache)

Tường lửa chống tự chấm

P7 0.953, `rank_shortlist` 0.871→0.955 và agent đơn S1 0.942 đến từ nhãn cùng họ mô hình tự chấm → **không phải kết quả**; `rank_shortlist` tắt mặc định. Khi tắt, P7 xếp hạng y hệt P6.

5.8 · CV THẬT — NLP501-BENCH V2

Thang hệ giữ vững trên văn bản thật

Hệ thống	test (18)	ours	coding	Djinni
B0 BM25	0.582	0.800	0.536	0.441
B2 hybrid	0.618	0.859	0.413	0.539
B3 luật ⊕ CE (v2)	0.729	0.801	0.669	0.704
B3 8 trục ⊕ CE	0.785	0.888	0.770	0.715
B4 pipeline cố định	**0.787**	**0.877**	**0.781**	**0.723**
P6 agent đầy đủ	0.782	0.882	0.805	0.696

8 trục luật hơn v2 +0.056 ($p=0.011$) và hơn truy hồi lai +0.167 ($p<0.001$). P6 ≈ B4 lần nữa (−0.005): luật đặt điểm ở cả hai.

5.9 · CÁC ĐÁNH GIÁ BỔ SUNG

Kể cả kết quả âm, vẫn giữ

Nghiên cứu	Kết quả
E19 ablation NLP (hedge, dùng/liệt kê, độ sâu, mốc ngày)	nDCG +0.001 đến +0.021: **âm**; nhưng phạm vi hedge giữ CV bẫy ngoài top 10 (0.00 vs 0.17)
E20 fine-tune cross-encoder trên JD dev	v1 test +0.046 (p=0.003); Djinni −0.027: **không chuyển sang CV thật**
E21 LLM chọn lọc vs LLM trên mọi ứng viên	P6 −47.4%, B4 −66.9% token; mất độ chính xác không có ý nghĩa
E23 pipeline trên 2.484 PDF résumé thật	đọc 100%; vai trò có mốc ngày 41.9% → 97.7%; nhận nhầm "testing tool" 17.2% → 1.6%
E24 học trọng số từ HR qua nhiều phiên	Δ −0.008 nDCG@10 (p=0.78): **âm**; giữ loại bỏ như quyết định cứng

6.1–6.2 · CA NGHIÊN CỨU

Mô hình chọn nơi tìm; code quyết định cái gì là dữ kiện

JD mơ hồ (JD-003): agent hỏi, các kiểm soát kích hoạt

```
[ingest] không có must-have cụ thể → hỏi HR (không LLM)
HR: "3+ năm, Selenium hoặc Playwright, English"
[ingest] ['selenium','playwright'] → nhóm one-of
[search] 43 ứng viên (3 thêm bởi điểm luật); 20 bị loại
[verify] 88/88 trích dẫn có căn cứ; 1/40 mâu thuẫn → gửi lại
[arbitrate] sát điểm Δ=0.022: đảo chiều thì lật (thiên lệch) → giữ thứ tự luật
[report] 8 xếp hạng, 22 không vào shortlist, 20 bị loại
```

CV nhiễu (syn_091): điều tra viên đọc được

```
read_section(summary) → "2 y#%rs%of e@%er%@%~e…"
propose(playwright)   → chấp nhận (khớp 0.80)
search(API testing)   → "U~ed P@aywrig@t, Postman…"
propose(api_testing)  → chấp nhận
— trên syn_043:
propose(python)       → từ chối (trích dẫn thiếu python, 0.50)
```

Trên 42 ca dàn dựng (qwen3:8b) và 17 ca (Sonnet 5.5): **0 phục hồi sai**. Trên benchmark, điều tra viên không cứu CV nào — đúng: trong các CV bị loại mà nó chọn, 36/37 được chấm 0–1.

6.3 · HR NHÌN THẤY GÌ

Thẻ giải thích cộng đúng tổng — JD-010, CV-033

Tiêu chí	w	điểm	đóng góp	bằng chứng (trích từ CV)
công cụ	0.20	92	0.184	must-have 3/3 · "Xây dựng framework Selenium + Java + TestNG..."
độ sâu tự động hoá	0.20	75	0.150	L3 từ động từ của chính ứng viên
kinh nghiệm	0.10	100	0.100	8.8 năm ở vai trò automation (10.8 tổng)
loại kiểm thử	0.10	100	0.100	"~200 RestAssured tests for loan and account APIs..."
CI/CD & hạ tầng	0.10	90	0.090	GitLab CI, Docker; Jenkins chỉ liệt kê (0.7)
ISTQB · ngôn ngữ · lĩnh vực	0.10 ×3	100	0.300	"ISTQB Advanced" · Java · English & ngân hàng
tổng			**0.924**	

Với ứng viên bị loại (CV-040): "Thiếu must-have: Selenium". **Nếu có** Selenium? Sẽ qua knock-out và đạt 0.855 — HR thấy chính xác ứng viên bị loại sát đến đâu.

7 · GIẢ THUYẾT · 8 · PHÂN TÍCH LỖI

Chấm theo những gì đo được

Giả thuyết (giữa kỳ)	Đo được	Kết luận
H1 agent hơn pipeline cố định	0.851 vs 0.839 (p=0.064)	**Không được ủng hộ**
H2 trọng tài chọn lọc giảm chi phí token	P6 ≈ 2.1× B4; so với LLM-mọi-CV −47% / −67%	**Một phần**
H3 kiểm chứng giữ giải thích có căn cứ	100% có căn cứ; nhận định 2.8% → 0.9%	**Đạt (lý do khác)**
H4 hồ sơ công ty khớp HR	τ 0.554 vs 0.542	**Không được ủng hộ***
H6 hỏi HR giúp trên JD mơ hồ	τ +0.056, nDCG +0.129 (p<0.001)	**Được ủng hộ**

Phân tích lỗi (test)	ours (6)	coding (4)
P6 agent đầy đủ	6 bỏ sót · 1 báo nhầm	4 bỏ sót · 1 báo nhầm
Ranker theo rubric	10 bỏ sót · 1	4 bỏ sót · 0

Hai chế độ lỗi: JD mơ hồ (hỏi HR lấy lại 57%) và CV *mô tả* tool mà không gọi tên (3/6 ca bỏ sót trên ours). *Nhãn H4 viết không có bối cảnh công ty.

9 · GIỚI HẠN & ĐẠO ĐỨC

Nêu rõ ràng

Nhãn người (ours)
120 cặp, κ 0.965; so với silver 0.66–0.70 → silver là bộ phụ. v1.1 giữ nguyên thứ tự (τ 1.00); con số vẫn là dữ liệu tổng hợp.

Thử nghiệm dữ liệu thật
Djinni 424 cặp (κ 0.696), là trung bình tổng hợp chứ chưa adjudicate; một bộ nhãn đã thấy điểm model; chỉ 8 JD.

Tập test nhỏ
10 JD → CI ±0.05–0.08; chênh lệch dưới ~0.03 không có ý nghĩa.

Tường lửa chống tự chấm
`rank_shortlist`, P7 0.953 và S1 0.942 không phải khẳng định về hiệu quả; tắt đến khi chạy đóng băng trên nhãn vàng người.

LLM được phục vụ
Claude qua Claude Code CLI thay cho API; số lượt gọi/token/hành vi giữ nguyên, độ trễ & chi phí thì không.

Đạo đức
Thuộc tính bảo vệ bị xoá trước khi index (twin: 0 thay đổi). Hệ gợi ý; HR quyết định, có ghi log.

10 · KẾT LUẬN · 11 · ĐÓNG GÓP

Agentic ở nơi luật không với tới

Xếp hạng
Bản tốt nhất (P6 0.851); thứ tự giữ nguyên khi người chấm (v1.1). CV thật: BM25 0.422 → luật 0.636 → P6 0.643.

Hành vi agentic
P7 đạt 40/42 (tác vụ HR) và 81/83 (mục tiêu phức tạp) — quay lại HR khi không đạt được mục tiêu.

Kiểm soát
Nơi chỉ có nhãn cùng họ mô hình chấm được thứ tự của LLM, kết quả không được công bố và tính năng để tắt.

Hệ giữ điểm trong luật tất định trên dữ liệu được xử lý tốt và kiểm mọi đầu ra LLM bằng code. Đánh giá của nó tìm ra lỗi mà unit test không bao giờ thấy. Tiếp theo: tập holdout Djinni đã khóa · E15 chạy lặp & HR thật · CV thật có sự đồng ý · tập test lớn hơn.

Đóng góp — Sơn: bài toán & tiêu chí · Vũ: tổng quan tài liệu (31 công trình) · Đán: agentic-HR, khoảng trống G1–G5, bộ coding, 8 trục luật, trọng tài hai chiều, thẻ giải thích · Phúc: nhãn mù cùng Hoa · Hoa: dữ liệu, độ đo, thẩm định · Thịnh: kiến trúc, agent, pipeline, benchmark, thực nghiệm.

CẢM ƠN · HỎI & ĐÁP

Một hệ xếp hạng CV agentic tạo niềm tin bằng cách agentic ở nơi luật không với tới