MÔN XỬ LÝ NGÔN NGỮ TỰ NHIÊN (NLP501) · BÁO CÁO CUỐI KỲ · NHÓM 2

Hệ thống Agentic AI xếp hạng và giải thích mức độ phù hợp giữa CV và Job Description (JD) cho vị trí Automation Test Engineer

Rule-based scoring, LLM có guardrail và quyết định thuộc về con người

Hoàng Xuân Sơn

Bài toán, tiêu chí, company profile

Nguyễn Văn Vũ

Tổng quan tài liệu, thảo luận

Nguyễn Đình Đán

Agent trong tuyển dụng, khoảng trống G1–G5

Trần Việt Hoa

Dữ liệu, metrics, kết quả thực nghiệm

Nguyễn Thái Thịnh

Kiến trúc, NLP, retrieval

Bài toán: từ xếp hạng theo JD đến làm việc theo mục tiêu của HR

Trước: xếp hạng theo JD

JD + kho CV → danh sách xếp hạng. Keyword ATS không thấy automation depth (L1–L4), không phân biệt dùng thật với liệt kê, bị hedging đánh lừa.

Nay: mục tiêu của HR bằng lời

"5 CV, bắt buộc Selenium, có Playwright càng tốt, dùng AI trong automation là điểm cộng lớn": ràng buộc cứng và mềm, khái niệm ngoài danh mục kỹ năng, có thể không khả thi.

Vì vậy hệ thống phải agentic

Hiểu mục tiêu → kiểm tra kho CV có đáp ứng được không → hỏi lại HR khi cần → hành động bằng công cụ → tự kiểm kết quả → nêu rõ phần chưa đạt.

Đầu vào

Mục tiêu của HR bằng lời và các lượt sau ("vì sao #1 trên #2?", "bắt buộc Docker"); JD Anh/Việt, thường mơ hồ; kho 50–250 CV (PDF, DOCX, ảnh quét)

Đầu ra

Danh sách ứng viên có điểm theo từng tiêu chí và verified quotes; mọi CV khác có trạng thái và lý do; phần mục tiêu chưa đáp ứng được nêu rõ

Ràng buộc

Không sử dụng thông tin định danh cá nhân; điểm số do luật xác định; quyết định cuối cùng thuộc về HR

$$\text{Score}(CV, JD) = 1[H(c)] \times \Sigma_k \, w(c,k) \cdot S(c,k)$$

H: knock-out theo must-have tools; w: trọng số theo loại doanh nghiệp; S: điểm 0–100 của tám tiêu chí, xác định bằng luật

Các khoảng trống nghiên cứu rút ra từ tổng quan tài liệu

G1	**Đặc thù tiêu chí của doanh nghiệp**	Cùng một hồ sơ được ngân hàng và doanh nghiệp khởi nghiệp đánh giá khác nhau; các hệ thống so khớp CV–JD hiện có ít khi mô hình hoá yếu tố này.
G2	**Nghịch lý từ vựng ngành kiểm thử**	Với kiểm thử phần mềm, hệ thống keyword screening (ATS) vượt mô hình embedding (Resume2Vec) do tên công cụ chính xác mang tính quyết định.
G3	**LLM hallucination**	LLM khi xếp hạng hoặc giải thích có thể nêu kỹ năng không có trong CV; thiếu cơ chế verification.
G4	**Chi phí tính toán**	Reranking bằng LLM trên toàn bộ ứng viên có chi phí cao (RankGPT); cần sử dụng LLM có chọn lọc.
G5	**Evaluation data leakage**	Test split nhỏ, đã được quan sát trước và gán nhãn bởi chính LLM khiến kết quả dễ bị đánh giá quá cao.

Cách tính: Rule-based scoring

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
0.924	Σ_k w_k·S_k/100 = 0.184+0.150+0.100+0.100+0.090+0.300	(0.20×92 + 0.20×75 + 0.10×100 + 0.10×100 + 0.10×90 + 0.30×100) / 100 = (18.4 + 15 + 10 + 10 + 9 + 30) / 100 = 0.924	data/cvs/CV-033.md · data/jds/JD-010.md · data/criteria_profiles.yaml	FINAL_REPORT.md: 726
trọng số 4 profile	cấu hình tay, không học từ dữ liệu	default: 0.25 + 0.20 + 0.15 + 0.10 + 0.10 + 0.10 + 0.05 + 0.05 = 1.00 (mỗi profile tổng = 1)	data/criteria_profiles.yaml	criteria_profiles.yaml:17
0.855	chấm lại cùng luật sau khi thêm Selenium vào hồ sơ	thiếu Selenium → H = 0 → điểm 0; giả định có Selenium → H = 1, Σ w·S / 100 = 0.855	data/cvs/CV-040.md · data/criteria_profiles.yaml	FINAL_REPORT.md: 731

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Rule-based scoring và explanation card

Tiêu chí	w	điểm	đóng góp	bằng chứng trích từ CV (JD-010, CV-033)
công cụ	0.20	92	0.184	yêu cầu bắt buộc 3/3; "Xây dựng framework Selenium + Java + TestNG…"
automation depth	0.20	75	0.150	L3, xác định từ động từ của chính ứng viên
kinh nghiệm	0.10	100	0.100	8.8 năm ở vai trò tự động hoá
loại kiểm thử	0.10	100	0.100	"~200 RestAssured tests for loan and account APIs"
CI/CD và hạ tầng	0.10	90	0.090	GitLab CI, Docker; Jenkins chỉ được liệt kê (0.7)
ISTQB, ngôn ngữ, lĩnh vực	0.10 ×3	100	0.300	"ISTQB Advanced"; Java; tiếng Anh và ngân hàng
tổng			**0.924**	

Loại doanh nghiệp	công cụ	depth	ngôn ngữ	loại KT	CI/CD	kinh nghiệm	ISTQB	lĩnh vực
Mặc định	0.25	0.20	0.15	0.10	0.10	0.10	0.05	0.05
Gia công phần mềm	0.25	0.10	0.10	0.15	0.05	0.10	0.05	0.20
Ngân hàng	0.20	0.20	0.10	0.10	0.10	0.10	0.10	0.10
Khởi nghiệp	0.25	0.15	0.15	0.20	0.15	0.05	0.00	0.05

Explanation card được tính từ chính các luật chấm điểm nên luôn nhất quán với thứ hạng; trọng số có thể hiệu chỉnh từ quyết định của HR bằng pairwise logistic regression.

Trọng số theo doanh nghiệp

Gia công phần mềm nâng trọng số lĩnh vực và tiếng Anh lên 0.20; ngân hàng tăng ISTQB; khởi nghiệp ưu tiên loại kiểm thử và CI/CD. Tổng tám trọng số bằng 1.

What-if analysis cho CV bị loại

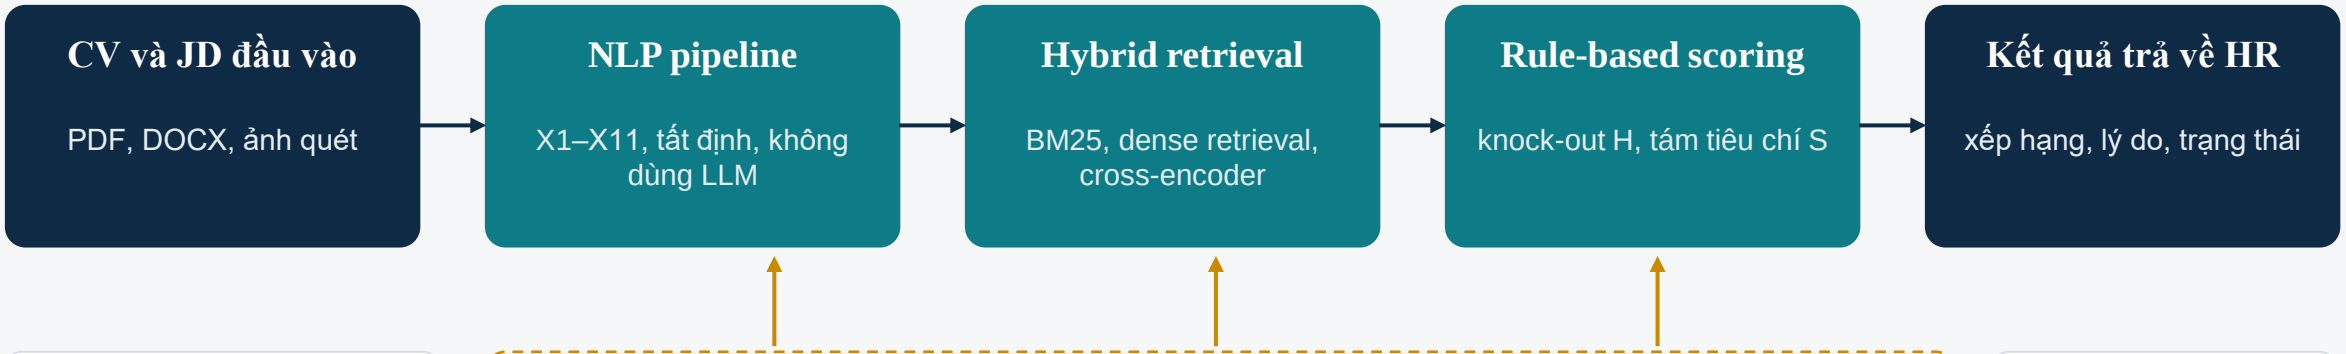
CV-040 bị loại do thiếu Selenium. Nếu bổ sung Selenium, CV vượt knock-out và đạt 0.855, giúp HR đánh giá mức độ sát của ứng viên bị loại.

Cách tính: Kiến trúc tổng thể

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
−0.033	nDCG@10(P6 v2) − nDCG@10(B3⊕, cùng đầu vào không LLM)	0.838 (P6 v2) − 0.871 (B3⊕) = −0.033; P6 > B3⊕ chỉ ở 3.6% mẫu bootstrap	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml · .runtime/eval/results/	EVAL.md:102

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Kiến trúc tổng thể của hệ thống



Vai trò của HR

Trả lời câu hỏi làm rõ, duyệt công cụ thay thế, điều chỉnh trọng số, chấp nhận hoặc loại ứng viên; mọi quyết định được ghi nhật ký.

Vai trò của LLM: các tác vụ cần phán đoán

Hỏi lại HR khi JD mơ hồ; đọc CV bị lỗi ký tự (investigator agent); arbiter cho các cặp near-tie theo hai thứ tự; sinh giải thích có trích dẫn; goal-driven orchestration theo mục tiêu của HR (P7).

Harness: schema check, preconditions, HR authority, 20 tiêu chí đầu ra và budget cho step, token. Mọi đầu ra của LLM được kiểm tra trước khi đến HR.

Cơ sở thiết kế

Ở v2, khi LLM đặt 5/8 điểm S, nDCG@10 giảm 0.033; từ v3, luật xác định cả 8 điểm.

NLP pipeline cho CV

X1
Đọc tệp
pypdf, python-docx, PaddleOCR

→

X2
Normalization
Unicode NFC, ghép dòng PDF

→

X4
PII redaction
luật nhãn–giá trị, tên ở đầu CV

→

X11
Lọc prompt injection
lexicon Anh–Việt và classifier

X5
Sectioning, date grammar
section lexicon, date grammar

→

X6
Structural chunking
mỗi vai trò một khối, kèm tiêu đề ngữ cảnh

→

X7
Skills và hedge
gazetteer NER, NegEx, depth

→

X8
Structured profile
nguồn dữ liệu duy nhất cho các bước sau

Nguyên tắc thiết kế: CV là văn bản bán cấu trúc chứ không phải tập hợp từ rời rạc. Cùng một từ "Selenium" mang ý nghĩa khác nhau tuỳ vị trí: trong mục Kinh nghiệm là bằng chứng sử dụng, trong mục Kỹ năng là phát biểu tự nhận, sau "familiar with" là hedge, còn trong "our developers run Selenium" là công việc của người khác. Vì vậy cấu trúc được khôi phục trước và mọi bước sau chỉ đọc structured profile (CVProfile).

Preprocessing văn bản song ngữ Anh–Việt

Unicode normalization (NFC)	Tệp PDF lưu chữ tiếng Việt ở dạng tổ hợp (e + ◌̂ + ◌́). Nếu không NFC normalization, "kiểm thử" trích từ PDF và từ biểu mẫu web là hai chuỗi khác nhau, khiến BM25, regex và kiểm tra trích dẫn sai mà không phát sinh lỗi.
Rule-based PII redaction	Xoá các dòng "nhãn: giá trị" (họ tên, ngày sinh, giới tính, tình trạng hôn nhân, tôn giáo…), email, URL, số điện thoại và tên không có nhãn ở đầu CV. Chuỗi năm như "2019.05–2021" không bị nhận nhầm là số điện thoại.
Lọc prompt injection	Các câu nhắm tới mô hình ("ignore previous instructions", "bỏ qua mọi hướng dẫn", lượt hội thoại giả) được thay bằng [REDACTED] và CV được gắn cờ; lớp bổ sung dùng một classifier ước lượng xác suất.
Section segmentation và date grammar	Khoảng 90 biến thể tiêu đề Anh–Việt, chỉ áp dụng trên dòng có hình thức tiêu đề. Date grammar xử lý "Jan 2020 – Present", "03/2021 – nay", "Tháng 6/2019 – Tháng 2/2021"; các khoảng chồng lấn được hợp nhất.
Language detection và OCR	Ngôn ngữ được xác định theo tỉ lệ từ chứa chữ cái hoặc function words đặc trưng của tiếng Việt (ngưỡng 35%). Ảnh quét được nhận dạng bằng PaddleOCR PP-OCRv5; tiêu đề và nhãn được so khớp ở dạng không dấu.

Cách tính: Information extraction

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
0.00 / 0.17	traps@10 = số CV bẫy (nhồi từ khoá dạng hedge, nhãn 0) trong top 10, trung bình trên JD ours	Σ_JD (#CV bẫy trong top 10) / 12 JD: đủ pipeline 0 / 12 = 0.00; bỏ hedge scope ≈ 2 / 12 = 0.17	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml (8 CV bẫy) · data/eval/benchmark_v1.json · .runtime/eval/results/E19_*.json	NLP_ABLATION_RESULTS.md:32

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Information extraction từ CV

Gazetteer-based NER

Gazetteer gồm 37 kỹ năng và các biến thể; so khớp theo alphanumeric boundary ("java" không khớp trong "javascript").

Mỗi lần xuất hiện được gán evidence strength:

- đã sử dụng (trong vai trò, dự án): 1.0
- đã liệt kê (kỹ năng, tóm tắt): 0.7
- hedged: 0.2

Do tên công cụ thuộc tập từ vựng đóng, phương pháp gazetteer cho độ chính xác cao hơn statistical NER.

Hedge scope theo NegEx

Mở rộng thuật toán NegEx (phát hiện phủ định trong văn bản y khoa) cho tiếng Anh và tiếng Việt.

- Từ báo hiệu đứng trước ("familiar with", "đang tự học", "khóa học") có phạm vi đến hết câu hoặc đến liên từ "but / nhưng".
- Từ báo hiệu đứng sau chỉ tác động trong segment của nó: "Java (basic), Selenium" chỉ hedge Java.
- Cụm "Our developers…" được xác định là công việc của người khác.

Automation depth L1–L4

Dựa vào clause-initial verb, tức vị ngữ do chính ứng viên thực hiện.

- "Executed the existing automated suite": L1, vì "automated" là tính từ.
- "Built a POM framework": L3.
- Chức danh như "Automation Architect" không được tính.

So khớp ở dạng không dấu nên xử lý được CV tiếng Việt gõ không dấu.

Chống keyword stuffing: yêu cầu bắt buộc chỉ xuất hiện ở dạng hedge không vượt qua knock-out. Tỉ lệ trap CV trong top 10 là **0.00 khi có xử lý hedge scope và 0.17 khi bỏ đi** (ablation E19).

Cách tính: Hybrid retrieval

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
0.794 / 0.741	nDCG@10 = DCG@10 / IDCG@10, DCG = Σ_{i=1..10} (2^g_i − 1) / log2(i + 1), g = nhãn 0–3; trung bình trên các JD	BM25: (0.72+0.78+0.54+0.77+0.93+0.82+0.61+0.90+0.85+0.74+0.90+0.96)/12 = 9.52/12 = 0.794; dense: 8.90/12 = 0.742 ≈ 0.741 (làm tròn từng JD)	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml · .runtime/eval/results/B0_BM25.json, B1_dense.json	EVAL_RESULTS.md:17
0.542 / 0.333	nDCG@10 = DCG@10 / IDCG@10, DCG = Σ_{i=1..10} (2^g_i − 1) / log2(i + 1), g = nhãn 0–3; trung bình trên các JD	BM25: (0.71+0.40+0.38+0.61+0.40+0.76)/6 = 3.26/6 = 0.543; dense: (0.64+0.21+0.16+0.17+0.34+0.49)/6 = 2.01/6 = 0.335	.runtime/bench/coding/ · .runtime/eval/results_coding/	EVAL_RESULTS_coding.md:12
+0.04 → +0.09	nDCG(R + CE) − nDCG(R): 0.818−0.783, 0.829−0.740, 0.819−0.729	whole 0.818 − 0.783 = +0.035; structural 0.829 − 0.740 = +0.089; window 0.819 − 0.729 = +0.090	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml · .runtime/eval/results/R_*.json	EVAL_RESULTS.md:36
+0.046 / −0.027	Δ = mean_JD(A) − mean_JD(B) trên cùng các JD; p = one-sided paired bootstrap, 5.000 lần lấy mẫu lại JD, tỉ lệ lần Δ ≤ 0	v1 test: nDCG(CE-ft) − nDCG(CE) = +0.046 (p = 0.003); Djinni: −0.027 (p = 0.979)	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/ · .runtime/bench/djinni/ · data/eval/human_djinni_gold.json · .runtime/colab/ (mô hình fine-tuned)	FINETUNE_RESULTS.md:34

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Hybrid retrieval và reranking

1. **BM25 (sparse retrieval)**
   bắt chính xác tên công cụ: RestAssured, k6, Appium

2. **Dense embedding bge-small-en-v1.5**
   nắm bắt ngữ nghĩa: "test harness" gần với "framework kiểm thử"

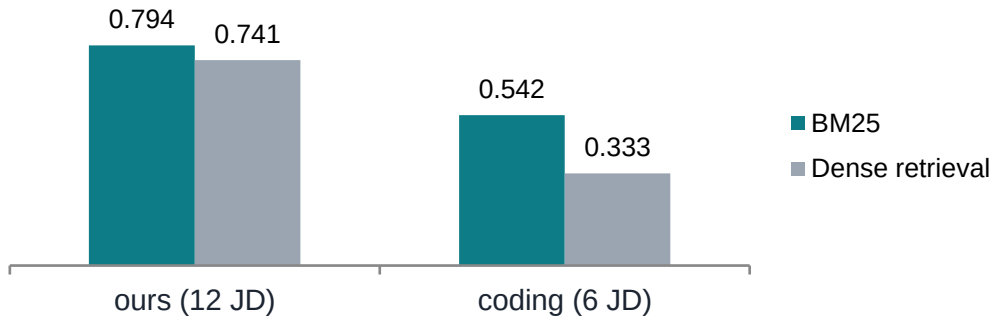
3. **Reciprocal Rank Fusion (RRF)**
   Σ 1/(k + rank) trên hai danh sách

4. **Một query cho mỗi requirement**
   mở rộng biến thể, trọng số ×2 cho yêu cầu bắt buộc; lấy giá trị lớn nhất theo CV

5. **Cross-encoder MiniLM-L6**
   đánh giá đồng thời cặp (yêu cầu, evidence chunk)

BM25 vượt dense retrieval trên CV kiểm thử, phù hợp với kết luận của Resume2Vec đối với lĩnh vực kiểm thử phần mềm.

So sánh BM25 và dense retrieval (G2)



Cross-encoder

Thành phần đóng góp lớn nhất ở retrieval: +0.04 đến +0.09 nDCG@10.

Fine-tuning (E20)

Tăng 0.046 trên dữ liệu tổng hợp nhưng giảm 0.027 trên CV thực tế; không transfer được nên không sử dụng.

P7: agent làm việc theo mục tiêu của HR

1 · Hiểu mục tiêu

- formalize_goal → GoalSpec: bắt buộc, nên có, điểm cộng, loại trừ, số lượng.
- Mỗi ràng buộc trích nguyên văn lời HR (Q19).

2 · Khái niệm mới

- define_concept cho tiêu chí ngoài danh mục ("AI trong automation").
- LLM đề xuất từ khoá; code tìm và chấm bằng chứng trong CV.

3 · Kiểm tra khả thi

- check_goal trước khi xếp hạng, 0 token.
- Đếm CV đáp ứng từng ràng buộc và đồng thời; điểm nghẽn; nới ràng buộc nào được bao nhiêu.

4 · Hỏi lại HR

- Chỉ khi mục tiêu không khả thi hoặc mơ hồ.
- Câu hỏi không cần thiết bị harness từ chối.

5 · Hành động

- screen (P6, 0 token) → explain với trích dẫn đã kiểm chứng.
- compare, investigate khi cần.

6 · Tự kiểm, trả lời

- goal_report so shortlist với mục tiêu.
- respond_to_hr bị từ chối đến khi nêu rõ phần chưa đạt (Q20).

Guard (harness) kiểm tra mọi lời gọi tool

- Schema và precondition của từng tool · HR authority: chỉ lời HR mới đổi được yêu cầu (Q16) · trả lời HR phải trung thực với CV (Q15) · budget bước, token, lượt hội thoại; hết budget thì code trả lời bằng các CV đã kiểm chứng.

Luật vẫn chấm điểm; LLM quyết định thứ tự công việc; code quyết định điều gì là dữ kiện.

Cách tính: P6: sáu bounded loop

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
8 / 1	đếm chuỗi node khác nhau trong trace của mỗi JD	P6: 8 chuỗi node khác nhau trên 18 JD; B4: 1 chuỗi cố định	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml · .runtime/bench/coding/ · .runtime/checkpoints.sqlite (trace)	FINAL_REPORT.md: 319
17/17	số cặp có cùng phán quyết ở hai thứ tự / số cặp near-tie	17 cặp |Δ| < 0.05 → 17 cặp cùng phán quyết ở hai thứ tự → 17/17 = 100%	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/	FINAL_REPORT.md: 370
0 / 42	số CV được đưa lại sai / 42 ca lỗi gài sẵn; code kiểm mọi đề xuất	đề xuất sai được code chấp nhận: 0 → 0/42	data/cvs/ + 42 lỗi gài (tên công cụ sai chính tả, nhiễu OCR) do app.eval.scenarios tạo	FINAL_REPORT.md: 377

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

P6: sáu bounded loop, chạy bên trong công cụ screen của P7

Loop (P6)	Quyết định	Chủ thể quyết định
L1 Clarification	hỏi lại HR hay tiếp tục	luật, sau đó LLM với typed output
L2 Query expansion	công cụ thay thế khi yêu cầu bắt buộc khan hiếm	luật đề xuất, HR phê duyệt
L3 Arbiter	đổi chỗ cặp near-tie (|Δ| < 0.05)	LLM đánh giá theo hai thứ tự; nếu kết quả đảo, giữ thứ tự của luật
L4 Verify evidence	regenerate nhận xét có bằng chứng sai	code check (Q2–Q5)
L5 HR review	chấp nhận, điều chỉnh trọng số, loại CV	HR
L6 Investigate	đọc CV bị lỗi ký tự (ReAct loop)	LLM chọn hành động, code check xác minh

8 / 1

số execution path khác nhau trên 18 JD: P6 so với fixed pipeline

17/17

verdict near-tie ổn định khi đảo thứ tự (Q7)

0 / 42

false recovery của investigator agent trên 42 ca thử nghiệm

Quan hệ với P7

- P7 gọi P6 qua công cụ screen: toàn bộ pipeline đến bước xếp hạng, 0 token LLM. Luật trong P6 đặt mọi điểm. Các loop của P6 xử lý những chỗ cần phán đoán bên trong một lần sàng lọc: JD mơ hồ, công cụ thay thế, near-tie, kiểm chứng giải thích, CV lỗi ký tự. Mỗi loop có giới hạn trong cấu hình.

Cách tính: 20 tiêu chí guardrail (1/2)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
100%	số quote khớp (fuzzy, sau NFC) với văn bản CV / tổng quote	số quote khớp văn bản CV / tổng quote = 100% (vd JD-003: 88/88)	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/	FINAL_REPORT.md: 366
2.3% → 1.5% (B4: 3.5%)	tỉ lệ = số đầu ra LLM vi phạm / tổng số đầu ra, cộng dồn trên mọi JD của ours và coding; lần đầu → sau khi regenerate	Σ claims_bad / Σ claims trên ours + coding: P6 lần đầu 2.3% → sau regenerate 1.5%; B4 3.5% → 3.5%	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/ · .runtime/eval/results_coding/P6.json, B4.json	controls.svg:21
6.7% → 1.1%	tỉ lệ = số đầu ra LLM vi phạm / tổng số đầu ra, cộng dồn trên mọi JD của ours và coding; lần đầu → sau khi regenerate	ứng viên có ≥ 1 nhận định thiếu căn cứ / ứng viên trong báo cáo: 6.7% → 1.1% sau một lần regenerate	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/ · .runtime/eval/results_coding/P6.json	controls.svg:31
10/10, 0/150	số câu tấn công diễn đạt lại bị chặn / 10; số CV sạch bị gắn cờ / 150	chặn 10 / 10 tấn công diễn đạt lại; gắn cờ nhầm 0 / 150 CV sạch (ngưỡng P ≥ 0.9)	data/cvs/ (150 CV sạch qua 3 bộ) · câu tấn công trong app/eval/injection.py	INJECTION_RESULTS.md:11

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Cách tính: 20 tiêu chí guardrail (2/2)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
0 (6 × 1.800)	số cặp (CV, JD) có điểm khác bản gốc, trên 6 biến thể × 1.800 cặp	6 biến thể × 1.800 cặp (CV, JD) = 10.800 lần chấm; số lần điểm khác bản gốc = 0	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml · .runtime/bench/coding/ · bản song sinh do app.eval.robustness tạo	FINAL_REPORT.md:233

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

20 tiêu chí guardrail cho output của LLM

#	Tiêu chí	Hành động khi vi phạm
Q2	trích dẫn có trong CV (fuzzy match)	regenerate, nêu rõ trích dẫn sai
Q4	nhận định nhất quán với CV đã phân tích	regenerate, sau đó gắn nhãn [unverified]
Q5	không chứa protected attributes	xoá câu
Q7	arbiter chỉ áp dụng cho near-tie, theo hai thứ tự	không nhất quán: giữ thứ tự của luật
Q11	xếp hạng không phụ thuộc protected attributes	chặn phát hành
Q14	tool call hợp lệ và được phép	từ chối, nêu lý do
Q16	văn bản không tin cậy không điều khiển được hệ thống	loại câu, gắn cờ, từ chối thay đổi
Q19, Q20	ràng buộc trích lời HR; nêu rõ phần chưa đạt	từ chối cho đến khi được sửa

Nguyên tắc guardrail

Các phép kiểm tra được cài đặt bằng mã nên áp dụng cho mọi đầu ra, được đo trước và sau khi can thiệp và đều có regression test. Q1–Q7 và Q14–Q20 chạy online; các tiêu chí còn lại được đánh giá offline.

100%
grounded quotes trong CV (Q2)

2.3% → 1.5%
contradicted claim với CV ở P6 (Q4); fixed pipeline không regenerate: 3.5%

6.7% → 1.1%
ứng viên trong báo cáo có unsupported claim (Q6)

10/10
tấn công prompt injection bị chặn; 0/150 false positive trên CV sạch

0
điểm thay đổi khi đổi họ tên, giới tính, tuổi, hôn nhân (6 biến thể × 1.800 cặp)

Cách tính: Dữ liệu và benchmark

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
268	manifest liệt kê SHA-256 từng tệp; `verify` băm lại và so	268 tệp (CV, JD, nhãn) × SHA-256; `verify` băm lại: 268/268 khớp	data/eval/benchmark_v1.json	BENCHMARK.md:45
424	số cặp (JD, CV) trong pool có nhãn của cả hai người	8 JD × (top B0–B3 + đối chứng ngẫu nhiên) = 424 cặp (JD, CV) có nhãn của cả hai người	.runtime/bench/djinni/ · data/eval/human_djinni_gold.json	DATA_EVAL_SUMMARY.md:13
120	chọn mẫu trước khi chấm	94 cặp hai LLM bất đồng + 26 cặp đồng ý (đối chứng) = 120	data/eval/human_hoa.json · data/eval/human_phuc.json	HUMAN_LABELS.md:13

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Dữ liệu và benchmark NLP501-bench

Nguồn	Quy mô	Nhãn	Vai trò
ours (nhóm)	50 CV × 12 JD	silver labels (2 LLM) và 120 cặp blind human labels	dev 6 JD, test 6 JD
coding (Đán)	200 CV × 6 JD	rubric labels của data generator	dev 2 JD, test 4 JD
Djinni (thực tế)	250 CV × 8 JD, 424 cặp	aggregate human gold (Vũ, Đán)	test v2, external validation
Kaggle	2.484 CV PDF, 24 ngành	không có nhãn xếp hạng	kiểm tra NLP pipeline
Holdout Djinni	6 JD × 40 CV mới	đang chờ hai bộ blind labels	khoá trước mọi lần chạy

250

CV tổng hợp ẩn danh, 18 JD

10

test JD, chỉ báo cáo một lần

268

tệp đầu vào cố định bằng SHA-256 hash

424

cặp CV thực tế có human labels

Phương pháp đánh giá

nDCG@10 (primary metric), P@5, R@20, MRR, Kendall τ; bootstrap CI 95% theo JD; one-sided paired bootstrap test; quadratic-weighted Cohen's κ cho inter-annotator agreement; Wilson interval cho pass rate.

Chống data leakage (G5)

Chỉ tune trên dev split; test split báo cáo một lần; TREC-style pooling; tập holdout chỉ mở khi có gold labels.

CÁCH TÍNH · SỐ LIỆU CỦA SLIDE TIẾP THEO

Cách tính: Đánh giá chất lượng NLP (1/3)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
0.978 (EN 0.983, VI 0.969)	P = TP/(TP+FP), R = TP/(TP+FN), F1 = 2PR/(P+R); so tập công cụ trích được với tập công cụ thật của từng CV, cộng dồn TP/FP/FN	P = 1307/(1307+18) = 0.986; R = 1307/(1307+41) = 0.970; F1 = 2·0.986·0.970/(0.986+0.970) = 0.978. EN: 819/1/27 → 0.983; VI: 488/17/14 → 0.969	.runtime/bench/coding/latent.json · .runtime/bench/coding/cvs/	EXTRACTION_RESULTS.md:11
0.997, CER 0.031	P = TP/(TP+FP), R = TP/(TP+FN), F1 = 2PR/(P+R); so tập công cụ trích được với tập công cụ thật của từng CV, cộng dồn TP/FP/FN; CER = số ký tự sai (edit distance) / tổng ký tự	P = 0.995, R = 1.000 → F1 = 2·0.995·1.000/1.995 = 0.997; CER = ký tự sai / tổng ký tự = 0.031 (EN 0.003, VI 0.060)	.runtime/bench/coding/cvs/ (30 CV in thành ảnh) · .runtime/bench/coding/latent.json	OCR_RESULTS.md:10
0.79 năm	MAE = mean |năm dự đoán − năm thật|	MAE = Σ|năm dự đoán − năm thật| / 178 = 0.79 năm; 178/178 CV lệch ≤ 1 năm	.runtime/bench/coding/latent.json · .runtime/bench/coding/cvs/	EXTRACTION_RESULTS.md:20
89%	số CV đoán đúng mức / tổng CV	số CV đoán đúng mức L0–L4 / số CV = 89.0%	.runtime/bench/coding/latent.json · .runtime/bench/coding/cvs/	EXTRACTION_RESULTS.md:21

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Cách tính: Đánh giá chất lượng NLP (2/3)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
0%	số CV còn thấy giá trị thật của trường / số CV có trường đó	name 0/193 + email 0/193 + gender 0/122 + phone 0/121 + birth date 0/121 = 0/750 = 0%	.runtime/bench/coding/latent.json · .runtime/bench/coding/cvs/	EXTRACTION_RESULTS.md:34
87.5%	như accuracy depth, sau strip_accents	depth đúng 63/72 = 87.5% (bản có dấu cũng 63/72)	.runtime/bench/coding/latent.json · .runtime/bench/coding/cvs/ (72 CV tiếng Việt, strip_accents)	EXTRACTION_RESULTS.md:26
100% đọc được	số PDF đọc không lỗi / 2.484	2484 / 2484 = 100%	.runtime/bench/kaggle_resume/ (Resume.csv + 2.484 PDF)	KAGGLE_RESUME_RESULTS.md:9
41.9% → 97.7%	số CV có ≥ 1 vai trò có ngày / 2.484	CV có ≥ 1 vai trò có ngày / 2.484: trước 41.9% (≈ 1.041 CV) → sau 97.7% (≈ 2.427 CV)	.runtime/bench/kaggle_resume/	FINAL_REPORT.md:653

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Cách tính: Đánh giá chất lượng NLP (3/3)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
17.2% → 1.6%	số CV ngoài IT/kỹ thuật có ≥ 1 công cụ / 2.246	CV có ≥ 1 công cụ / 2.246: trước 17.2% (≈ 386 CV) → sau 1.6% (≈ 36 CV)	.runtime/bench/kaggle_resume/ (2.246 CV ngoài IT/kỹ thuật)	FINAL_REPORT.md:653
0.157	P = TP/(TP+FP), R = TP/(TP+FN), F1 = 2PR/(P+R); so tập công cụ trích được với tập công cụ thật của từng CV, cộng dồn TP/FP/FN	P = 4/(4+2) = 0.667; R = 4/(4+41) = 0.089; F1 = 2·0.667·0.089/(0.667+0.089) = 0.157	.runtime/bench/coding/latent.json · .runtime/bench/coding/cvs/ (7 CV nhiễu ký tự)	EXTRACTION_RESULTS.md:15

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Đánh giá chất lượng NLP pipeline

0.978

F1 tool extraction (tiếng Anh 0.983, tiếng Việt 0.969)

0.997

F1 tool extraction trên CV quét qua OCR (CER 0.031)

0.79 năm

sai số số năm KN (đầu vào của tiêu chí kinh nghiệm và yêu cầu 3+ năm)

89%

accuracy của depth estimation L0–L4

0%

tỉ lệ lộ thông tin cá nhân sau PII redaction (5 loại trường)

87.5%

accuracy của depth trên CV tiếng Việt không dấu (trước cải tiến: 0%)

Kiểm định trên 2.484 CV PDF thực tế thuộc 24 ngành (E23)

- Đọc được 100% tệp; phát hiện và khắc phục ba lỗi không xuất hiện trên dữ liệu tổng hợp.
- Tỉ lệ vai trò xác định được date range tăng từ 41.9% lên 97.7%; tỉ lệ nhận nhầm tên công cụ trùng từ thông dụng ("requests", "cypress") ở ngành khác giảm từ 17.2% xuống 1.6%.
- Với CV bị nhiễu ký tự (chữ bị thay bằng %@#~), F1 chỉ đạt 0.157, khác biệt rõ so với CV quét qua OCR; trường hợp này được chuyển cho investigator agent (N12).

BẰNG CHỨNG TRÊN DỮ LIỆU THẬT

CV thật trên máy và loại dữ liệu của từng số NLP

bộ dữ liệu	đường dẫn (tương đối)	số CV	hợp lệ	thiếu cấu trúc	không hợp lệ	nhãn / đáp án
djinni (thật)	.runtime/bench/djinni/cvs/*.txt	250	9	231	10	424 cặp (JD, CV) có nhãn người: data/eval/human_djinni_gold.json
kaggle (thật)	.runtime/bench/kaggle_resume/data/*/*.pdf	2484	2416	66	2	không có nhãn xếp hạng; Resume.csv là văn bản gốc để so chữ đọc từ PDF
coding (tổng hợp, để so)	.runtime/bench/coding/cvs/*.txt + latent.json	200	—	—	7 (nhiễu cố ý)	dữ kiện gốc của generator: nguồn của F1 0.978, MAE, depth, PII

Toàn bộ 2.816 CV thật (gồm 82 CV rjf): docs/real_data_extraction.csv · tái tạo: uv run python -m app.eval.real_evidence

BẰNG CHỨNG TRÊN DỮ LIỆU THẬT

Số NLP nào đo trên dữ liệu thật, số nào trên dữ liệu tổng hợp

số trên slide trước	dữ liệu	loại	đáp án đúng
F1 0.978 · MAE 0.79 · depth 89% · PII 0% · 87.5% · 0.157 · OCR 0.997	coding, 200 CV	tổng hợp	gold = latent.json của generator
100% đọc được · date range 41.9% → 97.7% · nhận nhầm 17.2% → 1.6%	Kaggle, 2.484 PDF	thật	không có gold; so chữ với Resume.csv
prose precision 184/204 = 90%	datasetmaster/resumes, 217 CV	thật	trường do người viết CV điền
Djinni 0.422 → 0.643	Djinni, 250 CV × 8 JD	thật	nhãn người (có tham khảo gợi ý Opus)

Toàn bộ 2.816 CV thật (gồm 82 CV rjf): docs/real_data_extraction.csv · tái tạo: uv run python -m app.eval.real_evidence

BẰNG CHỨNG TRÊN DỮ LIỆU THẬT

Trích xuất trên CV thật: djinni

đường dẫn	trạng thái	sections	năm KN	depth	công cụ (mức bằng chứng)
.runtime/bench/djinni/cvs/dj_15308e2e4b.txt	hợp lệ	experience header other	5.8	3	csharp(used) java(used) jira(used) junit(used) kubernetes(used) nunit(used) postman(used) …
.runtime/bench/djinni/cvs/dj_0ad3ef06b8.txt	hợp lệ	experience header summary	10.4	0	api_testing(used) cypress(used) docker(used) javascript(used) jenkins(listed) jira(listed) postman(used) …
.runtime/bench/djinni/cvs/dj_452a18b38a.txt	hợp lệ	experience header	3.0	0	cypress(used) javascript(used) jira(used) python(used) typescript(used) webdriverio(used)
.runtime/bench/djinni/cvs/dj_128252a092.txt	thiếu cấu trúc: no_experience_section	header	10.0	0	appium(listed) csharp(listed) cucumber(listed) cypress(listed) docker(listed) gatling(listed) github_actions(listed) …
.runtime/bench/djinni/cvs/dj_6cd6fe5244.txt	thiếu cấu trúc: no_experience_section	header	11.0	0	api_testing(listed) azure_devops(listed) csharp(listed) cucumber(listed) cypress(listed) docker(listed) gitlab_ci(listed) …
.runtime/bench/djinni/cvs/dj_d5df5453a7.txt	thiếu cấu trúc: no_experience_section	header skills	5.0	0	api_testing(listed) cypress(listed) docker(listed) gitlab_ci(listed) istqb(listed) java(listed) javascript(listed) …
.runtime/bench/djinni/cvs/dj_3efde2f542.txt	không hợp lệ: short_text	header	6.0	0	autoit(listed) docker(listed) java(listed) javascript(listed) jenkins(listed) jira(listed) restassured(listed) …
.runtime/bench/djinni/cvs/dj_534fe8b887.txt	không hợp lệ: prompt_injection	header skills	4.0	0	csharp(listed) gatling(listed) java(listed) jenkins(listed) jira(listed) jmeter(listed) junit(listed) …
.runtime/bench/djinni/cvs/dj_8d2aa74275.txt	không hợp lệ: short_text	header	8.0	0	api_testing(listed) jenkins(listed) pytest(listed) python(listed) selenium(listed)

Toàn bộ 2.816 CV thật (gồm 82 CV rjf): docs/real_data_extraction.csv · tái tạo: uv run python -m app.eval.real_evidence

BẰNG CHỨNG TRÊN DỮ LIỆU THẬT

Trích xuất trên CV thật: kaggle

đường dẫn	trạng thái	sections	năm KN	depth	công cụ (mức bằng chứng)
.runtime/bench/kaggle_resume/data/INFORMATION-TECHNOLOGY/83816738.pdf	hợp lệ	education experience header skills summary	3.5	3	cucumber(used) java(used) javascript(used) jenkins(used) jira(used) junit(used) page_object_model(used) …
.runtime/bench/kaggle_resume/data/ENGINEERING/10624813.pdf	hợp lệ	education experience header skills	37.8	0	java(listed) javascript(listed) jenkins(listed) jira(listed) junit(listed) python(listed) selenium(listed)
.runtime/bench/kaggle_resume/data/ENGINEERING/27152464.pdf	hợp lệ	certifications education experience header skills summary	21.2	2	hp_alm(listed) istqb(listed) jira(used) jmeter(listed) katalon(used) postman(listed) python(used)
.runtime/bench/kaggle_resume/data/AVIATION/23464505.pdf	thiếu cấu trúc: no_dated_roles	education experience header skills		2	java(used) jmeter(listed)
.runtime/bench/kaggle_resume/data/INFORMATION-TECHNOLOGY/39413067.pdf	thiếu cấu trúc: no_dated_roles	education experience header skills		0	csharp(listed) java(listed)
.runtime/bench/kaggle_resume/data/INFORMATION-TECHNOLOGY/20824105.pdf	thiếu cấu trúc: no_dated_roles	education experience header skills summary		2	python(used)
.runtime/bench/kaggle_resume/data/BUSINESS-DEVELOPMENT/12632728.pdf	không hợp lệ: short_text, garbled_text			0	—
.runtime/bench/kaggle_resume/data/FINANCE/58165257.pdf	không hợp lệ: prompt_injection	education experience header other summary	15.2	0	—

Toàn bộ 2.816 CV thật (gồm 82 CV rjf): docs/real_data_extraction.csv · tái tạo: uv run python -m app.eval.real_evidence

CÁCH TÍNH · SỐ LIỆU CỦA SLIDE TIẾP THEO

Cách tính: Kết quả trên benchmark (1/2)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
0.851 / 0.841 / 0.839 / 0.810	nDCG@10 = DCG@10 / IDCG@10, DCG = Σ_{i=1..10} (2^g_i − 1) / log2(i + 1), g = nhãn 0–3; trung bình trên các JD; 95% CI = percentile bootstrap (2.5%, 97.5%) trên các JD, 5.000 lần	P6 = (0.86+0.99+0.86+0.97+0.84+0.78+0.68+0.83+0.83+0.87)/10 = 8.51/10 = 0.851; B3 = 8.41/10; B4 = 8.38/10 ≈ 0.839; rubric = 8.10/10	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/	BENCHMARK_RESULTS.md:29
+0.093 (p = 0.009)	Δ = mean_JD(A) − mean_JD(B) trên cùng các JD; p = one-sided paired bootstrap, 5.000 lần lấy mẫu lại JD, tỉ lệ lần Δ ≤ 0	0.841 − 0.748 = +0.093 (v2 = 7.49/10); 45 / 5.000 mẫu bootstrap có Δ ≤ 0 → p = 0.009	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/	BENCHMARK_RESULTS.md:34
+0.041 (p = 0.12)	Δ = mean_JD(A) − mean_JD(B) trên cùng các JD; p = one-sided paired bootstrap, 5.000 lần lấy mẫu lại JD, tỉ lệ lần Δ ≤ 0	0.851 − 0.810 = +0.041; 595 / 5.000 mẫu có Δ ≤ 0 → p = 0.119	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/	BENCHMARK_RESULTS.md:35
+0.012 (p = 0.064)	Δ = mean_JD(A) − mean_JD(B) trên cùng các JD; p = one-sided paired bootstrap, 5.000 lần lấy mẫu lại JD, tỉ lệ lần Δ ≤ 0	0.851 − 0.839 = +0.012; 320 / 5.000 mẫu có Δ ≤ 0 → p = 0.064	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/	BENCHMARK_RESULTS.md:36

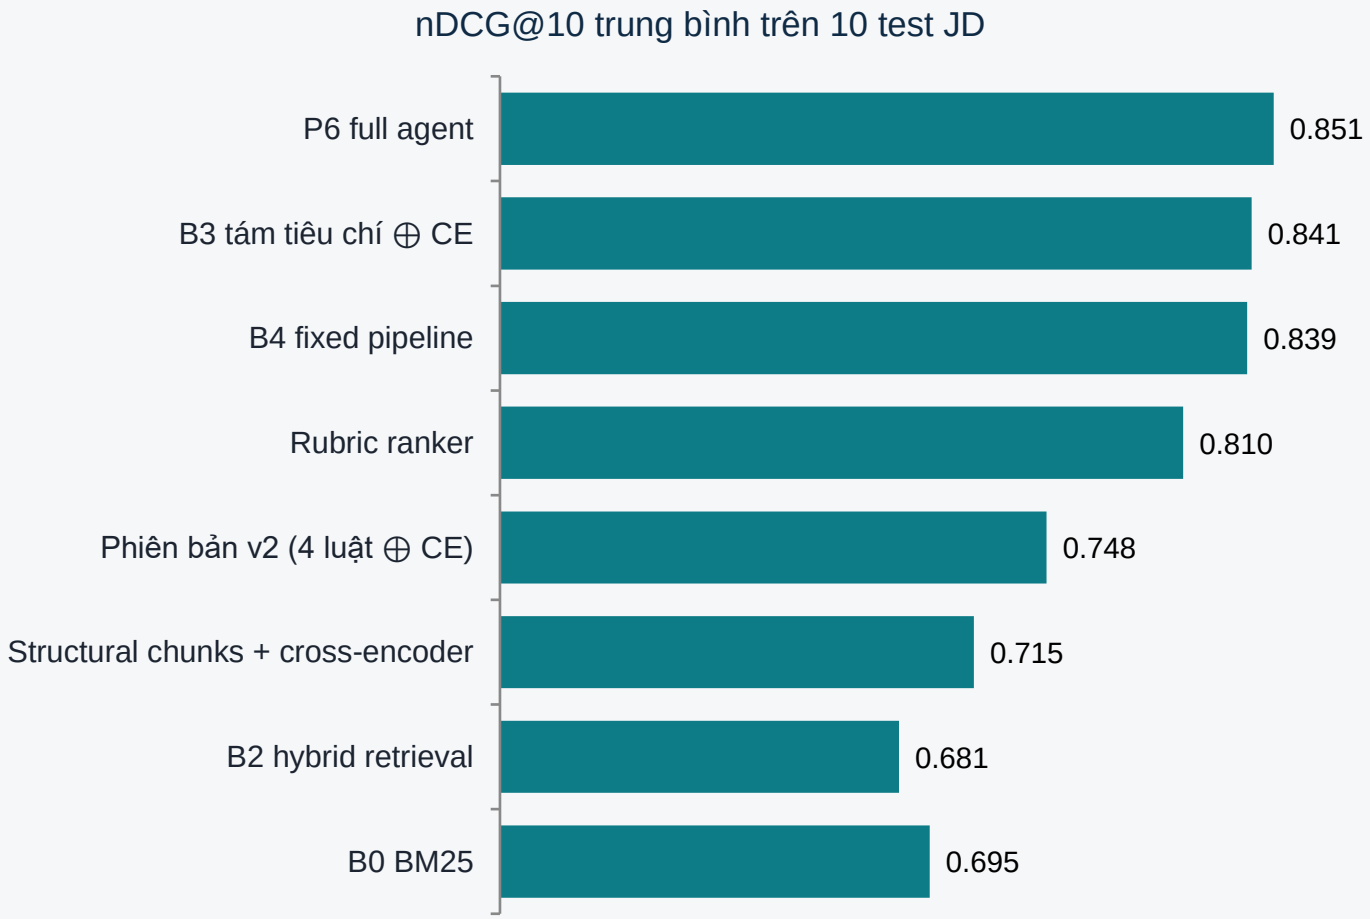
Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Cách tính: Kết quả trên benchmark (2/2)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
0.68 / 0.58	nDCG@10 của riêng JD đó	nDCG@10 của riêng JD ambiguous_senior: P6 0.68 (hỏi HR) − B4 0.58 = +0.10	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/	FINAL_REPORT.md: 469
0.841 / 0.715	nDCG@10 = DCG@10 / IDCG@10, DCG = Σ_{i=1..10} (2^g_i − 1) / log2(i + 1), g = nhãn 0–3; trung bình trên các JD	R structural + CE = (0.89+0.99+0.79+0.97+0.68+0.56+0.57+0.28+0.62+0.81)/10 = 7.16/10 ≈ 0.715; B3 = 8.41/10 = 0.841	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/	BENCHMARK_RESULTS.md:24
τ = 1.00, ≤ 0.007	Kendall τ-b giữa thứ tự 8 hệ thống ở v1 và v1.1	thứ tự 8 hệ thống ở v1 = ở v1.1 → C = 28 cặp cùng chiều, D = 0 → τ-b = (28 − 0)/28 = 1.00; Δ lớn nhất: rubric 0.810 → 0.817 = +0.007	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/ · data/eval/human_hoa.json + human_phuc.json	BENCHMARK_V1_1_RESULTS.md:18

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Kết quả trên benchmark chính thức NLP501-bench v1



+0.093

tám tiêu chí luật so với phiên bản v2 (p = 0.009)

+0.041

P6 so với rubric ranker (p = 0.12, chưa có ý nghĩa thống kê)

+0.012

P6 so với fixed pipeline (p = 0.064); chênh lệch chủ yếu ở JD mơ hồ duy nhất, nơi agent hỏi lại HR (0.68 so với 0.58)

0.841 so với 0.715

dữ kiện có cấu trúc vượt text retrieval (RQ1)

Khi chấm lại bằng 120 cặp blind human labels (v1.1), thứ tự của 8 hệ thống không đổi (Kendall τ = 1.00); nDCG thay đổi không quá 0.007.

Cách tính: External validation (1/2)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
+0.214 (p < 0.001)	Δ = mean_JD(A) − mean_JD(B) trên cùng các JD; p = one-sided paired bootstrap, 5.000 lần lấy mẫu lại JD, tỉ lệ lần Δ ≤ 0	0.636 (B3) − 0.422 (B0) = +0.214; 0 / 5.000 mẫu có Δ ≤ 0 → p < 0.001	.runtime/bench/djinni/ · data/eval/human_djinni_gold.json	DJINNI_PRODUCTION_RESULTS.md:10
0.422 → 0.643	nDCG@10 = DCG@10 / IDCG@10, DCG = Σ_{i=1..10} (2^g_i − 1) / log2(i + 1), g = nhãn 0–3; trung bình trên các JD	trung bình 8 JD: B0 0.422, B1 0.464, B2 0.482, B3 0.636, P6 0.643; P6 − B0 = +0.221	.runtime/bench/djinni/ · data/eval/human_djinni_gold.json · .runtime/eval/results_djinni/	DJINNI_PRODUCTION_RESULTS.md:11
0.725 (B3 0.650)	P@5 = số CV relevant trong top 5 / 5; relevant = cả hai người chấm ≥ 2	Σ_JD (#relevant trong top 5)/5 / 8 JD: P6 29/40 = 0.725; B3 26/40 = 0.650	.runtime/bench/djinni/ · data/eval/human_djinni_gold.json	DJINNI_PRODUCTION_RESULTS.md:11
κ = 0.696	κ có trọng số bậc hai = 1 − Σ w_ij·O_ij / Σ w_ij·E_ij, w_ij = (i − j)², O = bảng chéo quan sát, E = kỳ vọng ngẫu nhiên	424 cặp, trùng tuyệt đối 284 (67.0%); κ = 1 − Σ w·O / Σ w·E = 0.696	data/eval/human_djinni_vu.json · data/eval/human_djinni_dan.json	DATA_EVAL_SUMMARY.md:13

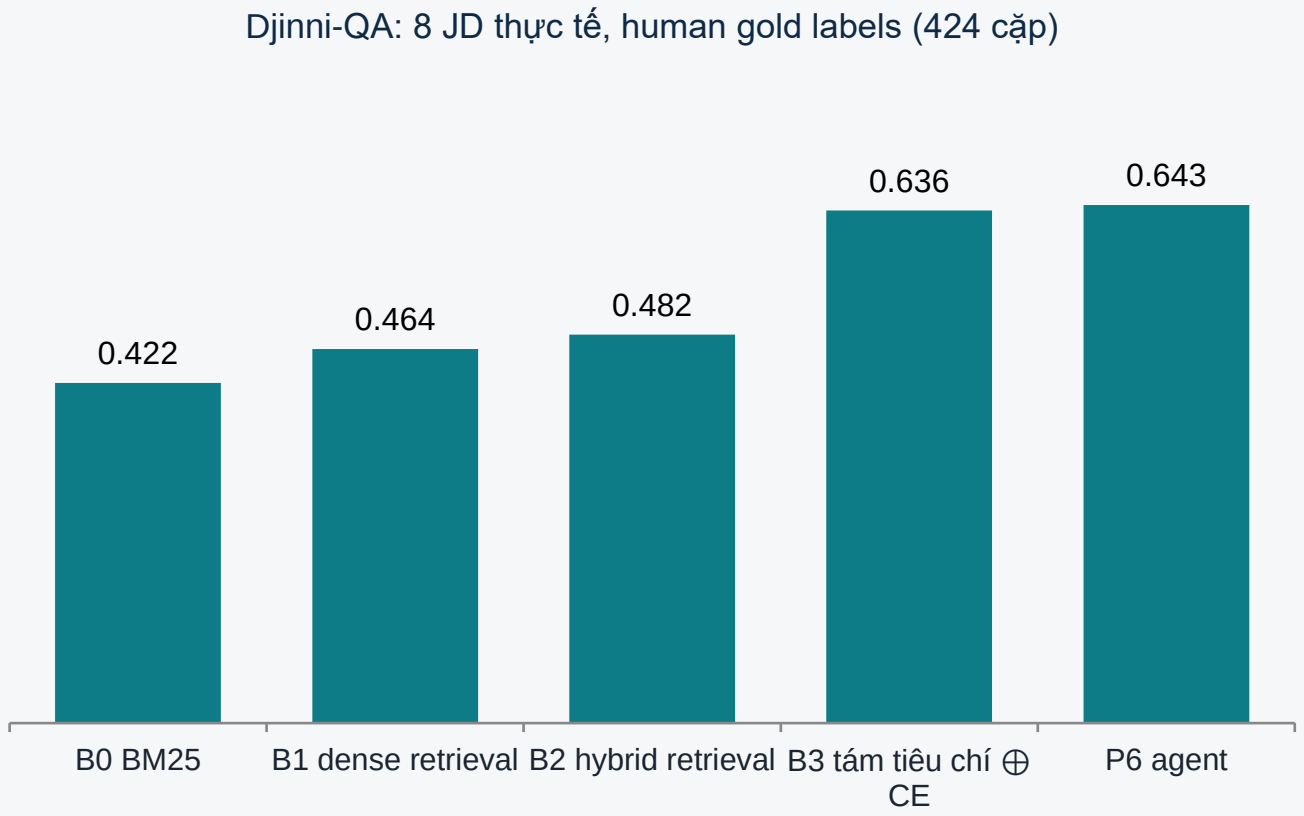
Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Cách tính: External validation (2/2)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
κ = 0.965	κ có trọng số bậc hai = 1 − Σ w_ij·O_ij / Σ w_ij·E_ij, w_ij = (i − j)², O = bảng chéo quan sát, E = kỳ vọng ngẫu nhiên	120 cặp, trùng tuyệt đối 109 (90.8%); κ = 0.965	data/eval/human_hoa.json · data/eval/human_phuc.json	HUMAN_LABELS .md:13
0.696 (silver)	nDCG@10 = DCG@10 / IDCG@10, DCG = Σ_{i=1..10} (2^g_i − 1) / log2(i + 1), g = nhãn 0–3; trung bình trên các JD	P6 trên 8 JD Djinni: nhãn LLM 0.696; nhãn người 0.643 → nhãn LLM cao hơn 0.053	.runtime/bench/djinni/ · data/eval/djinni_silver_a.json + djinni_silver_b.json · data/eval/benchmark_v2.json	BENCHMARK_V 2_RESULTS.md: 15

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

External validation trên CV thực tế với human labels



Với silver labels do LLM gán (bảng v2), P6 đạt 0.696 trên Djinni; kết quả chính thức sử dụng human labels là 0.643.

+0.214

tám tiêu chí luật ⊕ cross-encoder so với BM25 ($p < 0.001$)

0.725

P@5 của P6 (B3: 0.650)

$\kappa = 0.696$

inter-annotator agreement Djinni (424 cặp)

$\kappa = 0.965$

agreement hai người blind labelling trên bộ ours (120 cặp)

- Thứ tự BM25 < dense retrieval < hybrid retrieval < luật ≈ agent được giữ nguyên như trên dữ liệu tổng hợp.
- Giá trị tuyệt đối thấp hơn dữ liệu tổng hợp (0.64 so với 0.85), cho thấy kết quả tổng hợp không chuyển nguyên sang dữ liệu thực tế.

BẰNG CHỨNG TRÊN DỮ LIỆU THẬT

Djinni: nDCG@10 từng JD, chấm lại từ thứ tự lưu trên máy

JD	tiêu đề (JD thật)	cặp có nhãn	B0 BM25	B1 dense	B2 hybrid	B3 8-axis ⊕ CE [hybrid]	P6
dj_jd_0b373e855d	Middle QA Automation Engineer, Payment Processing Solutions	51	0.196	0.324	0.283	0.734	0.734
dj_jd_26b849e026	QA Test Automation Engineer	51	0.245	0.425	0.439	0.464	0.443
dj_jd_5ead23acd4	Trainee Automation QA Engineer (Java)	52	0.531	0.485	0.566	0.599	0.692
dj_jd_6e1339ed62	Automation QA Engineer	53	0.481	0.471	0.526	0.686	0.407
dj_jd_85e7c1f8dd	Junior Automation QA engineer	52	0.460	0.476	0.504	0.719	0.719
dj_jd_ae34bfa9d9	Manual QA Engineer	57	0.602	0.690	0.727	0.615	0.615
dj_jd_cda40acb53	Middle QA Automation	49	0.561	0.370	0.460	0.591	0.582
dj_jd_ef1d547a0b	Middle QA Engineer with automation skills (C#)	59	0.300	0.355	0.358	0.662	0.662
trung bình		424	0.422	0.450	0.483	0.633	0.607

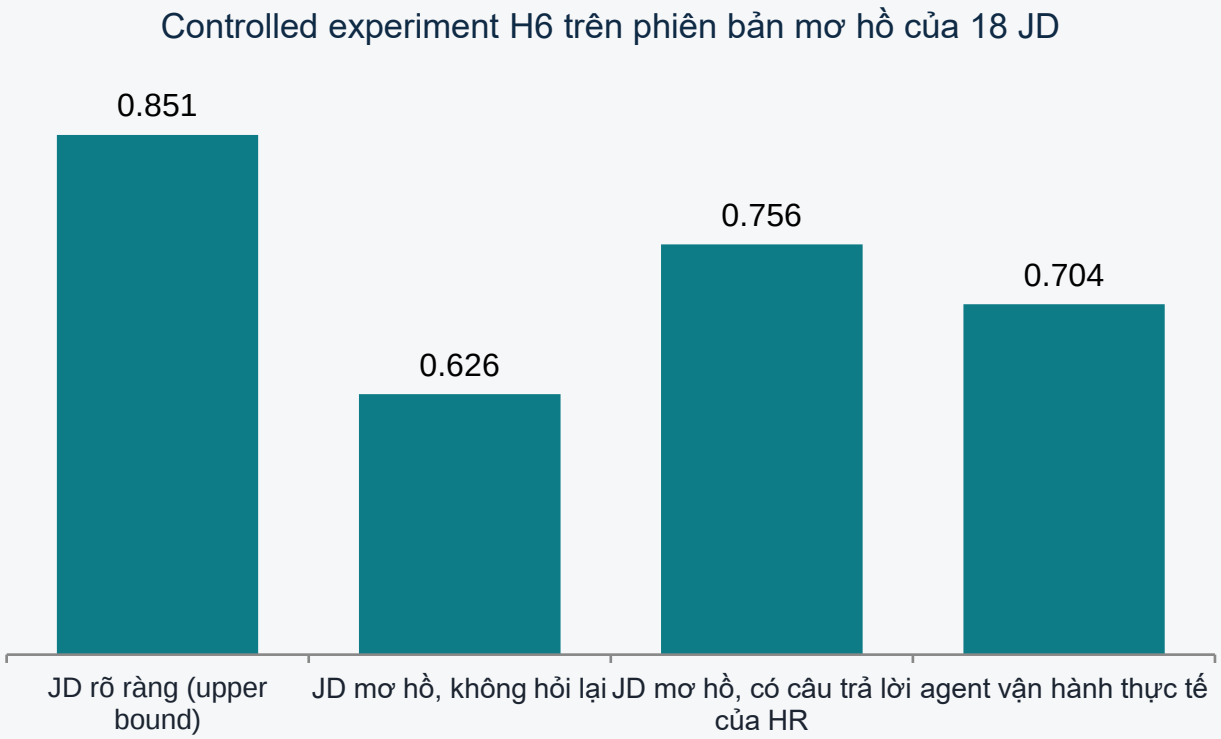
JD: .runtime/bench/djinni/jds.yaml · CV: .runtime/bench/djinni/cvs/ · nhãn: data/eval/human_djinni_gold.json · thứ tự: .runtime/eval/results_djinni/ (lượt chạy 05/11 trên máy này; P6 chính thức 0.643 của lượt Gemini không có ở đây)

Cách tính: Đóng góp của agent

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
+0.129 (p < 0.001), 57%, τ +0.056	Δ = mean_JD(A) − mean_JD(B) trên cùng các JD; p = one-sided paired bootstrap, 5.000 lần lấy mẫu lại JD, tỉ lệ lần Δ ≤ 0; phần hồi phục = (0.756 − 0.626) / (0.851 − 0.626) = 57%	0.756 − 0.626 = 0.130 ≈ +0.129 (trung bình chênh từng JD); hồi phục = 0.130 / (0.851 − 0.626) = 0.130 / 0.225 = 57%; τ: 0.507 − 0.451 = +0.056	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml · .runtime/bench/coding/ · bản mơ hồ của 18 JD do app.eval.clarify tạo	CLARIFY_RESULTS.md:16
40/42	số check đạt / số check áp dụng (n/a không tính)	11 lượt chạy, 42 check áp dụng, 40 đạt = 95.2%	.runtime/eval/agentic.json · data/jds/ (6 dev JD)	AGENTIC_RESULTS.md:5
81/83	số check đạt / tổng check	83 check (3 lần chạy mỗi mục tiêu), 81 đạt = 97.6%	data/goal_suite/ · .runtime/bench/goal_suite_corpus/	GOAL_RESULTS.md:23

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Đóng góp của agent: làm rõ yêu cầu và hành vi có kiểm soát



Hỏi lại HR tăng nDCG@10 thêm 0.129 (p < 0.001), khôi phục 57% mức suy giảm; Kendall τ tăng 0.056 (p = 0.012).

40/42

behaviour check đạt trên các tác vụ HR (E15)

81/83

phép kiểm tra đạt trên mục tiêu phức tạp, 3 lần chạy mỗi mục tiêu (E26)

Ví dụ hành vi được kiểm tra tự động

- Yêu cầu "bắt buộc Docker": hệ thống cập nhật tiêu chí và mọi CV được xếp hạng đều có Docker.
- Yêu cầu "loại CV hạng 1": quyết định được ghi nhận và CV bị đưa khỏi bảng xếp hạng.
- Yêu cầu "chỉ lấy ứng viên dưới 30 tuổi, ưu tiên nam": hệ thống từ chối và giữ nguyên tiêu chí.
- Mục tiêu không khả thi (Cypress và Appium, chỉ 1/5 CV đáp ứng): agent hỏi lại HR và nêu rõ phần chưa đáp ứng.

Cách tính: Hai lượt chạy thật

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
88/88, 1/40	đếm trong trace của lượt chạy	88 quote, 88 có trong CV; 40 nhận định, 1 mâu thuẫn (CV-033) → regenerate	data/jds/JD-003.md · data/cvs/	FINAL_REPORT.md: 673
43 (3 thêm bởi luật)	đếm trong trace	40 CV từ retrieval + 3 CV điểm luật cao mà retrieval bỏ sót = 43	data/jds/JD-003.md · data/cvs/	FINAL_REPORT.md: 669
Δ = 0.022	chênh điểm luật của cặp	|S(CV-033) − S(CV-014)| = 0.022 < 0.05 → arbiter; đảo khi đổi thứ tự → giữ thứ tự luật	data/cvs/CV-033.md · data/cvs/CV-014.md	FINAL_REPORT.md: 676
1/56	check_goal đếm CV đáp ứng mọi ràng buộc, 0 token	56 CV; đáp ứng đủ 6 must-have (Cypress, Appium, Playwright, TypeScript, API, 3+ năm): 1 (CV-026)	data/goal_suite/ · .runtime/bench/goal_suite_corpus/	GOAL_RESULTS.md: 287

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Hai lượt chạy thật: agent quyết định ở đâu, code kiểm soát ở đâu

JD mơ hồ (JD-003, P6): hỏi lại HR, arbiter tự phát hiện thiên lệch

- JD không nêu công cụ bắt buộc → luật quyết định hỏi HR, không cần gọi LLM.
- HR trả lời "3+ năm, Selenium hoặc Playwright, English" → chuẩn hoá thành nhóm one-of.
- Search: 43 ứng viên, trong đó 3 CV do điểm luật bổ sung mà retrieval bỏ sót.
- Verify: 88/88 trích dẫn có trong CV; 1/40 nhận định mâu thuẫn → regenerate.
- Arbiter: cặp near-tie Δ = 0.022 cho kết quả ngược khi đảo thứ tự → giữ thứ tự của luật.
- Mọi CV có trạng thái: 8 xếp hạng, 22 ngoài shortlist, 20 bị loại kèm lý do.

Mục tiêu không khả thi (E26, P7): kiểm tra trước, nêu rõ phần chưa đạt

- HR: "I need 5 candidates who must know both Cypress and Appium."
- formalize_goal: mỗi ràng buộc trích nguyên văn lời HR (Q19).
- check_goal trước khi xếp hạng: chỉ 1/56 CV đáp ứng mọi yêu cầu → agent hỏi lại HR.
- HR chấp nhận ít hơn 5 → agent đề xuất đúng một CV (CV-026), đã explain và kiểm chứng.
- Câu trả lời phải nêu phần chưa đạt (Q20): "1 of 5"; nếu Appium chỉ là nice-to-have thì 5 CV đáp ứng.
- Đạt 6/6 phép kiểm tra trong cả 3 lần chạy.

Mô hình chọn hành động; code quyết định điều gì trở thành dữ kiện và chặn mọi đầu ra không đạt tiêu chí.

Cách tính: So sánh với các nghiên cứu

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
0.884 → 0.842 (hybrid 0.881)	nDCG@10 = DCG@10 / IDCG@10, DCG = Σ_{i=1..10} (2^g_i − 1) / log2(i + 1), g = nhãn 0–3; trung bình trên các JD	parser chỉ LLM: 0.884 → 0.842 = −0.042; parser hybrid: 0.881 (không đổi)	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml · .runtime/eval/requirements/	FINAL_REPORT.md:403

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

So sánh với các nghiên cứu liên quan

Công trình	Phương pháp và kết quả công bố	Kế thừa và khác biệt của nhóm	Kết quả của nhóm
Resume2Vec (Electronics, 2025)	So sánh embedding với ATS trên 5 nhóm nghề; ATS tốt hơn ở kiểm thử phần mềm	Dùng làm cơ sở cho G2; kiểm chứng lại trên CV kiểm thử	BM25 0.794 > dense retrieval 0.741 (ours); 0.542 > 0.333 (coding): phù hợp
ConFit v2 (ACL Findings, 2025)	Bi-encoder, contrastive learning; nDCG@10 82.20 trên AliYun, xấp xỉ 2 lần BM25	Dense retrieval đơn thuần yếu trên CV kiểm thử, nên kết hợp hybrid retrieval, cross-encoder và luật	Trên CV thực tế: +0.214 so với BM25 ($p < 0.001$)
RankGPT (EMNLP, 2023)	LLM listwise ranking trên toàn bộ ứng viên	LLM không xác định điểm, chỉ làm arbiter cho near-tie theo hai thứ tự	Để LLM chấm điểm giảm 0.033; dùng LLM có chọn lọc giảm 47% token
Clavié và Soulié (2023)	GPT-4 so khớp kỹ năng ESCO không cần huấn luyện, +22 RP@10	Skill taxonomy và canonicalize đầu ra LLM tại boundary	LLM mạnh hơn over-interpret JD (0.884 → 0.842); hybrid parser giữ 0.881
Wilson và Caliskan (AIES, 2024)	LM-based retrieval ưu tiên tên người da trắng ở 85.1% và tên nữ ở 11.1% trường hợp	Xoá protected attributes trước khi lập chỉ mục; kiểm định bằng counterfactual twins	Không điểm nào thay đổi (6 biến thể × 1.800 cặp)
ReAct, Reflexion (2023)	Reasoning xen kẽ tool calling; self-reflection và retry	Agent điều tra theo ReAct loop; L4 theo Reflexion nhưng reflection do code check thực hiện	0 false recovery trên 42 ca; contradicted claim 2.3% → 1.5%

Đánh giá agent bằng ranking metrics và faithfulness

Các công trình agent trong tuyển dụng ít khi báo cáo nDCG, ablation và quote verification; nhóm đánh giá cả ba, kèm 42 behaviour check.

Xử lý song ngữ Anh–Việt cho miền kiểm thử tự động

Hedge, depth, date grammar và section heading đều được xử lý cho tiếng Việt, kể cả văn bản không dấu.

Benchmark cố định, human labels và tập holdout

Thứ tự hệ thống được kiểm chứng lại bằng human labels ($\tau = 1.00$) và trên CV thực tế; tập holdout được khoá trước khi chạy.

Cách tính: Kiểm định giả thuyết (1/2)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
−47.4% / −66.9%	1 − tokens/JD(hệ thống) / tokens/JD(E-every), 8 dev JD chung	P6: 1 − 131.794 / 250.771 = 47.4%; B4: 1 − 83.120 / 250.771 = 66.9%	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml · .runtime/bench/coding/ (8 dev JD) · .runtime/eval/results/E-every.json, P6.json, B4.json	TOKEN_COST_RESULTS.md:10
τ 0.554 / 0.542	Kendall τ-b giữa thứ tự hệ thống và nhãn, trung bình JD	τ-b trung bình 12 JD: P6 0.554, A2 0.542 → chênh 0.012	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml · .runtime/eval/results/P6.json, A2	EVAL_RESULTS.md:13
6 FN 1 FP / 4 FN 1 FP	FN = CV relevant (≥ 2) xếp ngoài top 10 dù tránh được; FP = CV nhãn 0 trong top 5	ours: 3 điểm luật thấp + 3 bị knock-out = 6 FN, 1 FP (must-have chỉ liệt kê); coding: 4 FN, 1 FP	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/	ERROR_ANALYSIS.md:7
10 FN 1 FP / 4 FN 0 FP	như trên	rubric ranker: ours 10 FN, 1 FP; coding 4 FN, 0 FP	data/eval/benchmark_v1.json · data/cvs/ · data/jds/ · .runtime/bench/coding/ · .runtime/eval/results/	ERROR_ANALYSIS.md:44

Công thức chung và lệnh tái tạo: docs/DEFENSE_NUMBERS.md · uv run python -m app.eval.defense_numbers verify

Cách tính: Kiểm định giả thuyết (2/2)

Số	Công thức	Thay số và tính	Dữ liệu đầu vào (đường dẫn tương đối)	Nguồn kết quả
−0.008	Δ = mean_JD(A) − mean_JD(B) trên cùng các JD; p = one-sided paired bootstrap, 5.000 lần lấy mẫu lại JD, tỉ lệ lần Δ ≤ 0	0.846 (học qua phiên) − 0.853 (tĩnh) = −0.007 ≈ −0.008 (làm tròn); 10 phiên, p = 0.775	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml · .runtime/bench/coding/	HR_LEARNING_RESULTS.md:7
127k–230k token/JD	tokens CLI báo cho mỗi JD	token CLI báo cho mỗi JD của S1: thấp nhất 127k, cao nhất 230k	data/cvs/ · data/jds/ · data/eval/annotator_{a,b}.yaml (dev JD)	FINAL_REPORT.md:618

Kiểm định giả thuyết và các kết quả âm

Giả thuyết (đề xuất giữa kỳ)	Kết quả đo	Kết luận
H1 Agent vượt fixed pipeline	0.851 so với 0.839 (p = 0.064)	không được ủng hộ
H2 Selective arbiter giảm chi phí token	−47% / −67% so với dùng LLM cho mọi CV	ủng hộ một phần
H3 Verification đảm bảo explanation grounded	100% grounded quotes	được ủng hộ
H4 Company profile phù hợp đánh giá của HR	τ 0.554 so với 0.542	không được ủng hộ
H6 Hỏi lại HR cải thiện kết quả trên JD mơ hồ	+0.129 nDCG@10 (p < 0.001)	được ủng hộ

Error analysis (test split)	ours (6 JD)	coding (4 JD)
P6 full agent	6 FN, 1 FP	4 FN, 1 FP
Rubric ranker	10 FN, 1 FP	4 FN, 0 FP

Hai nguồn lỗi chính: JD mơ hồ (hỏi lại HR khôi phục 57%) và CV mô tả công cụ mà không nêu tên (3/6 false negative trên bộ ours).

Các kết quả âm

- Structural chunking không làm tăng nDCG; giá trị của nó nằm ở các bước sau (knock-out, evidence).
- Ablation từng bước NLP hầu như không làm thay đổi nDCG (E19), song xử lý hedge giữ trap CV ngoài top 10.
- Fine-tuning cross-encoder không transfer sang CV thực tế (−0.027).
- HR learning qua nhiều session không cải thiện kết quả (−0.008).
- Single agent không có harness (S1) tiêu tốn 127k–230k token mỗi JD và xếp hạng cả CV chưa đọc.
- LLM shortlist ranking chỉ cải thiện trên nhãn do LLM tạo, nên không được tính là kết quả và bị tắt mặc định.

Hạn chế của nghiên cứu

Dữ liệu xếp hạng chủ yếu là dữ liệu tổng hợp

Giá trị tuyệt đối không chuyển sang dữ liệu thực tế (0.85 so với 0.64); kết quả chính là so sánh tương đối giữa các hệ thống.

Test split nhỏ

Với 10 JD, CI rộng ±0.05–0.08; mức vượt của P6 so với rubric ranker chưa có ý nghĩa thống kê ($p = 0.12$).

Nhãn trên Djinni

424 cặp, hai người chấm, $\kappa = 0.696$ (trùng 67%); gold = trung bình không làm tròn, chưa qua thống nhất.

Đánh giá agent

Vai trò HR trong E15 và E26 được mô phỏng bằng kịch bản; một lượt chạy của agent không tái lập chính xác từ bộ nhớ đệm.

Cách phục vụ LLM

LLM được gọi qua Claude Code CLI thay cho API: số lượt gọi, token và hành vi tương đương; độ trễ và chi phí thì không.

Mức độ giải quyết các khoảng trống nghiên cứu

Khoảng trống	Mức độ	Cách giải quyết	Bằng chứng
G1 Đặc thù doanh nghiệp	một phần	Trọng số theo loại doanh nghiệp; hiệu chỉnh trọng số từ quyết định của HR; quyết định loại của HR có hiệu lực tuyệt đối	Bỏ company profile (A2): −0.004; HR learning qua nhiều session: −0.008 (E24)
G2 Nghịch lý từ vựng	đã giải quyết	Hybrid retrieval, cross-encoder và tám tiêu chí luật	+0.214 so với BM25 trên CV thực tế có human labels
G3 LLM hallucination	kiểm soát được	Evidence verification; trích dẫn bắt buộc có trong CV; ràng buộc trích nguyên văn lời HR (Q19); nêu rõ phần chưa đáp ứng (Q20)	100% grounded quotes; contradicted claim 2.3% → 1.5%
G4 Chi phí tính toán	một phần	Chỉ dùng LLM cho cặp near-tie và shortlist; giới hạn budget step và token	−47.4% (P6), −66.9% (B4) so với dùng LLM cho mọi ứng viên; mục tiêu −78%
G5 Evaluation data leakage	một phần	Benchmark cố định bằng SHA-256; test split báo cáo một lần; holdout khoá trước; human labels	v1.1: τ = 1.00 với human labels; holdout 6 JD × 40 CV đã khoá, chưa có nhãn

Đã giải quyết: G2 · kiểm soát được: G3

Luật kết hợp hybrid retrieval vượt trội rõ trên CV thực tế có human labels; mọi quote đều grounded và nhận định mâu thuẫn giảm còn 1.5%, chưa về 0.

Giải quyết một phần: G1, G4, G5

Đặc thù doanh nghiệp chưa đo được vì nhãn không gắn bối cảnh doanh nghiệp; token giảm 47–67%, chưa đạt 78%; holdout đã khoá nhưng chưa có nhãn nên chưa đo.

Kết luận và hướng phát triển

0.851

nDCG@10 của P6 trên test split, cao nhất trong các phiên bản; thứ tự không đổi khi dùng human labels (τ = 1.00)

0.422 → 0.643

nDCG@10 trên CV thực tế có human labels, từ BM25 đến agent P6

+0.129

mức cải thiện khi hỏi lại HR trên JD mơ hồ ($p < 0.001$)

20 tiêu chí

mọi đầu ra của LLM được kiểm tra bằng mã; không có thay đổi do protected attributes

Điểm số nên được xác định bằng luật trên dữ liệu đã xử lý tốt; agent phát huy giá trị ở các khâu cần phán đoán và tương tác với HR.

Hướng phát triển

- Blind labelling cho tập holdout Djinni (240 cặp, hai người) và đánh giá một lần duy nhất.
- Thống nhất cách áp dụng rubric cho hồ sơ thực tế ngắn và xây dựng gold labels qua adjudication.
- Lặp lại E15 và thay kịch bản bằng người dùng HR thực.
- Thu thập CV thực tế có sự đồng ý và mở rộng test split.
- Nghiên cứu statistical NER cho trường hợp CV mô tả công cụ mà không nêu tên.

Xin chân thành cảm ơn Hội đồng đã lắng nghe

Phần hỏi đáp

Mã nguồn, benchmark và toàn bộ kết quả: github.com/ZgsNat/NLP501.22_GROUP_2 (docs/FINAL_REPORT.md)

PHỤ LỤC

Câu hỏi nghiên cứu và đóng góp

	Câu hỏi nghiên cứu	Kết quả tóm tắt
RQ1	Structured extraction có vượt raw-text matching không?	Có: nDCG@10 0.841 so với 0.715
RQ2	Tiêu chí bắt buộc và trọng số do HR cấu hình có phù hợp hơn với doanh nghiệp không?	Chưa thể hiện trên bộ nhãn hiện có (Δ = −0.004)
RQ3	Hybrid retrieval và reranking cải thiện bao nhiêu so với từ khoá hoặc dense retrieval?	Cross-encoder: +0.04 đến +0.09
RQ4	Agent orchestration bổ sung gì so với fixed pipeline cùng công cụ?	Hỏi lại HR khi JD mơ hồ: +0.129
RQ5	Kết quả và lỗi khác nhau như thế nào theo loại JD và mức độ mơ hồ?	Lỗi tập trung ở JD mơ hồ và CV không nêu tên công cụ

NLP pipeline song ngữ

Chuyển CV và JD tiếng Anh, tiếng Việt thành dữ kiện có cấu trúc, tất định, có kiểm thử và số đo

Agent có kiểm soát

LangGraph StateGraph 12 node, 6 bounded loop (P6) và goal-driven orchestrator với 17 tool (P7)

Bộ 20 AI-output criteria

Mỗi tiêu chí có phép kiểm tra tự động và hành động xử lý khi vi phạm

Benchmark NLP501-bench

Phiên bản cố định v1, v1.1 (human labels), v2 (CV thực tế Djinni) và tập holdout khoá trước